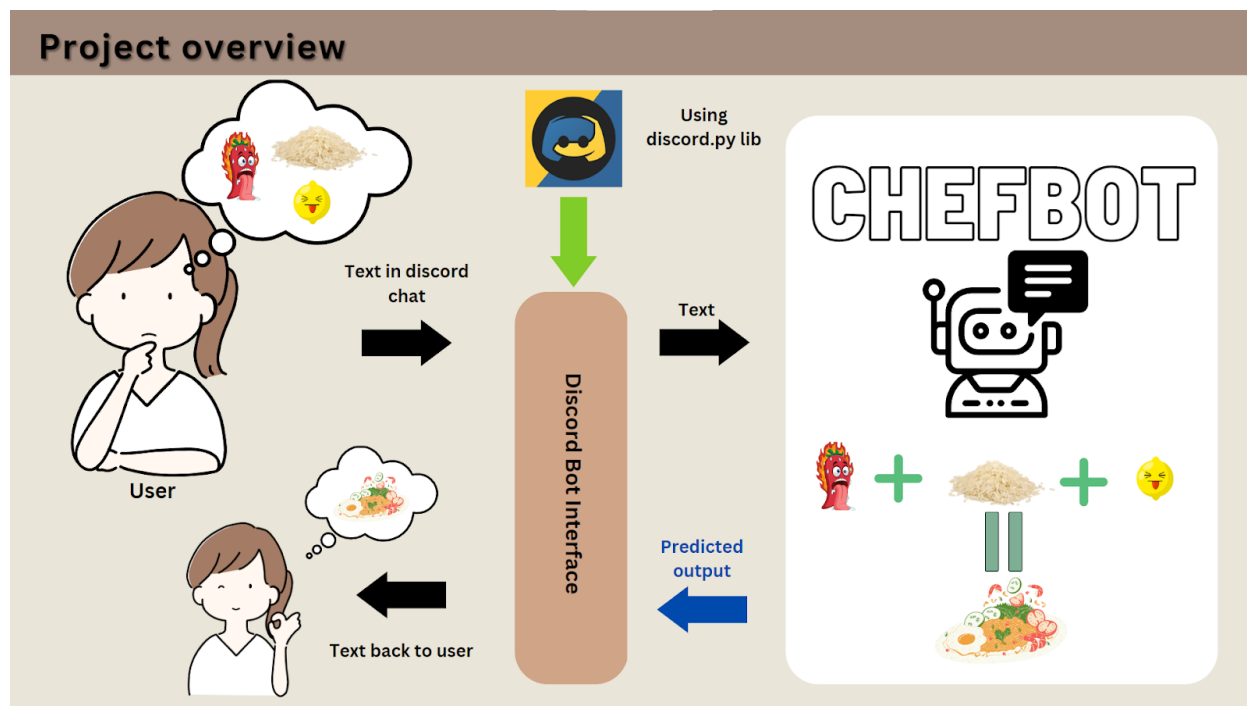


## Project Overview



## Project Description

Chatbot สำหรับผู้ที่กำลังมองหาสูตรอาหารใหม่ๆ เพื่อลองอาหารใหม่ๆ หรือไม่รู้จะกินอะไรดีแต่มีบางอย่างในใจอยู่แล้ว ไม่ว่าจะเป็น ส่วนผสม เนื้อสัมผัสของอาหาร รสชาติ อาหารประจำชาติ หรือวัตถุดิบที่มีอยู่ในมือ โครงการนี้สาธิตกระบวนการและวิธีการสร้างแชทบอทที่สามารถให้คำแนะนำเกี่ยวกับอาหารที่คุณควรทำหรือรับประทาน ตามข้อมูลเกี่ยวกับอาหารที่ใส่ไปในแชทบอท แชทบอทจะถูกสร้างขึ้นโดยใช้เทคนิค Natural Language Processing (NLP) และ Machine learning ที่จะได้รับการ Train ข้อมูลเกี่ยวกับชุดข้อมูลของสูตรอาหาร ลักษณะเฉพาะ และส่วนผสมที่เกี่ยวข้องเพื่อเรียนรู้วิธีการทำนายเมนูออกไป

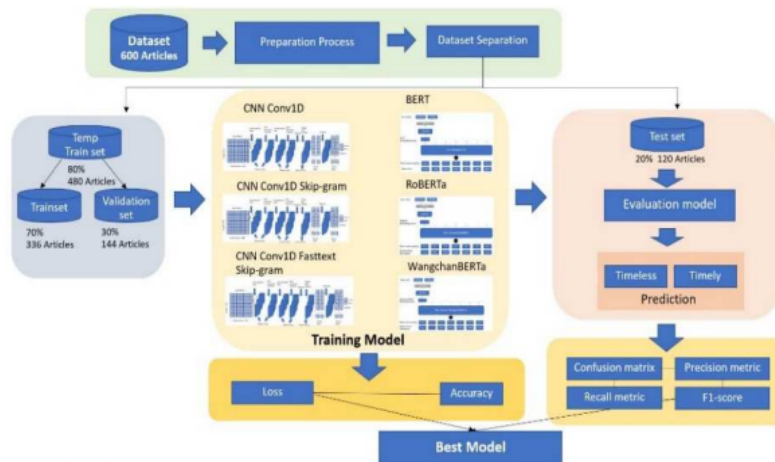
## Introduction and Literature review

### เอกสาร 1 : Thai text classification experiment using CNN and Transformer models for Timely-Timeless content marketing

#### What is being done?

เอกสารการวิจัยนี้มีเป้าหมายเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำ Classification ระหว่าง Timeless article และ Timely article โดยผู้วิจัยได้นำอัลกอริทึมที่มี

อยู่ในปัจจุบันมาใช้ทั้งสองวิธีหลักคือ Convolutional Neural Network (CNN) และ โมเดล Transformer



How is it being done?

## Related Works

### 1. Timely and timeless

การศึกษางานวิจัยก่อนหน้านี้ (Web page classification as evergreen or ephemeral based on content) ผู้วิจัยได้ใช้ Linear SVM ในการทำ Classification โดยได้ความแม่นยำประมาณ 87% โดยผู้วิจัยได้ทำการสร้างตัว Stop words และลบ Outlier ใน Dataset ออกไปพร้อมกับ อีกรางงานหนึ่งได้ความแม่นยำประมาณ 88% โดยใช้เทคนิค Term Frequency-Inverse Document Frequency (TF-IDF)

### 2. CNN

ผู้วิจัยได้ทดลองนำ CNN ไปวิเคราะห์ประเภทและรูปแบบการเขียนเชิงทัศนคติของบทกวีไทย แต่ผลที่ได้มีความแม่นยำเพียง 61% เพื่อปรับปรุงความแม่นยำ ผู้วิจัยจึงใช้วิธีทำโมเดลแบบผสม ที่เรียกว่าโมเดล Bi-LSTM CNN พร้อมทั้งทำ Embedding ซึ่งได้คะแนน F1 Score ที่ 74.36%, 77.07% และ 55.21% สำหรับ Dataset ภาษาไทยสามชุด (ThaiTales, ThaiEconTwitter และ Wiselight)

### 3. Transformer

การใช้โมเดล Transformer-based ถูกจำกัดความสามารถจากความพร้อมของโมเดล Pre-trained ที่ผ่านการเรียนรู้มาล่วงหน้าในภาษาที่เฉพาะทางและแตกต่างออกไป เช่น ภาษาไทย ซึ่งในปี พ.ศ. 2564 นักวิจัยไทยได้พัฒนาโมเดล Pre-trained Transformer ชื่อว่า WangchanBERTa ซึ่งมีความแม่นยำสูงในการจำแนกข้อความบน Wiselight Sentiment Dataset

## What is the dataset?

ชุดข้อมูลภาษาไทยที่ถูกเก็บจากเพจ Facebook ของ Aizhongchina ตั้งแต่เดือนมกราคม 2019 ถึงเดือนตุลาคม 2021 จากการศึกษา เพจ Facebook นี้โพสต์เกี่ยวกับเรื่องราวในประเทศจีนเป็นหลัก มีผู้ติดตาม 280,000 คน และค่าเฉลี่ยจำนวนการใช้งานหนึ่งล้าน

ครั้งต่อเดือน เมื่อได้รับอนุญาตจากเจ้าของเพจ ผู้วิจัยจึงทำการเรียกข้อมูลด้วยตนเอง ชุดข้อมูลที่ดึงมาประกอบด้วย 600 บทความ (อย่างน้อย 250 คำต่อบทความ) และแบ่งออกเป็นสองประเภท คือ Timeless และ Timely

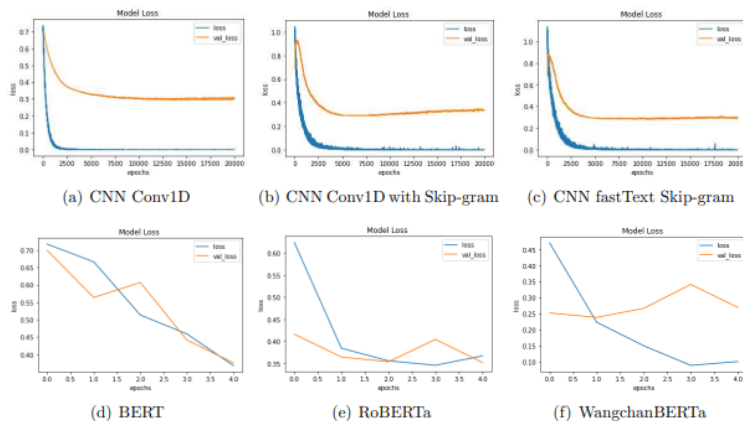
1. หากเป็นประเภทข่าวหรือเรื่องราวอัปเดตเกี่ยวกับสิ่งที่กำลังเป็นกระแสในช่วง 7 วันที่ผ่านมา และเป็นที่รู้จักในวงกว้างในช่วงเวลาหนึ่ง ก็จะจัดอยู่ในประเภท Timely
2. หากเป็นบทความประเภทเล่าเรื่องทั่วไปที่ให้ความรู้โดยไม่มีคีย์เวิร์ดตามกระแสก็จัดอยู่ในประเภท Timeless

บทความทั้งหมด 600 บทความ ถูกแยกแบบสุ่มเป็นข้อมูลสามชุด: Train, Validation และ Test set ในตอนแรก 600 บทความถูกแยกออกเป็น Training set และ Testing set โดยมีอัตราส่วน 80 : 20 (Training set 480 ชุด และ Testing set 120 ชุด) จากนั้นจึงแยกชุดการฝึก 480 บทความอีกครั้งด้วยอัตราส่วน 70 : 30 นั่นคือ 336 บทความสำหรับ Train และ 144 บทความสำหรับ Validation

### Evaluation metric

การวัดผลโมเดลผู้วิจัยได้ใช้จำนวน Epoch ทั้งหมด 10,000-20,000 Epochs ในโมเดล CNN และใช้ทั้งหมด 10 Epochs ในโมเดล Transformer ทั้งหมด ผู้วิจัยได้ทำการตั้งค่า Learning rate คือ 0.00005 ทั้งโมเดล CNN และ Transformer ตั้งค่า Batch sizes ของ CNN และ Transformer คือ 32 และ 6 ตามลำดับ

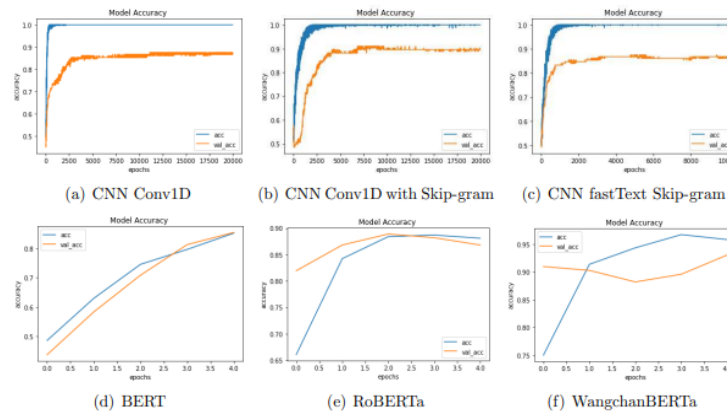
#### 1. Evaluation by loss value



จากภาพ Validation loss ของโมเดล CNN Conv1D ยังคงเสถียรตั้งแต่ 10,000 Epochs ในขณะที่ Validation loss ของโมเดล CNN Conv1D with Skip-gram เพิ่มขึ้นอย่างมากตั้งแต่ 6,000 Epochs, โมเดล Conv1D with fastText Skip-gram มีความเสถียรมากกว่า CNN Conv1D with Skip-gram ในส่วนของโมเดล Transformer อีกสามโมเดลแสดงแนวโน้มค่า Loss ที่ลดลง โดยเฉพาะค่า Validation loss อย่างไรก็ตาม Training Loss ของ RoBERTa และ WangchanBERTa เพิ่มขึ้นหลังจากผ่านไป 3 Epochs ในขณะที่ Validation loss ลดลง, ทั้ง Training Loss และ Validation loss ของ RoBERTa และ WangchanBERTa ผลที่ดีกว่าของ BERT

อย่างเห็นได้ชัด เมื่อเปรียบเทียบทุกโมเดล โมเดลที่ดีที่สุดจากการดูค่า Loss คือ WangchanBERTa ที่มีค่า Training Loss และ Validation loss น้อยที่สุด

## 2. Evaluation by accuracy value



โมเดล CNN Conv1D with Skip-gram มีค่า Training accuracy ใกล้เคียงกับ CNN Conv1D แต่มีความผันผวนมากกว่าโมเดล CNN Conv1D, ค่า Validation accuracy ของโมเดล CNN Skip-gram มีค่าใกล้เคียง 0.9 แต่ก็มีค่าความผันผวนมาก เช่นเดียวกัน ในโมเดลตัวสุดท้ายของ CNN คือ CNN Conv1D fastText Skip-gram มีค่าความผันผวนน้อยที่สุดและมีค่าความแม่นยำประมาณ 0.9 ซึ่งถือว่าดีที่สุด ในโมเดล CNN ทั้งหมด ส่วนของโมเดล Transformer, โมเดล BERT มีแนวโน้มที่ค่าความแม่นยำทั้ง Training และ Validation จะเพิ่มขึ้น และได้ค่าความแม่นยำที่สูงกว่า 0.8 ด้วย Epoch เพียง 5 Epochs เท่านั้น ในตอนเริ่มต้นโมเดล RoBERTa มีแนวโน้มที่ค่าความแม่นยำจะลดลง แต่สุดท้ายก็ยังได้ค่าความแม่นยำใกล้เคียงกับ 0.9 ทำให้ได้ค่าความแม่นยำสูงกว่า BERT สำหรับโมเดลตัวสุดท้าย คือโมเดล WangchanBERTa ได้ค่าความแม่นยำสูงสุดที่ 0.95 และ 0.90 ทั้งของ Training และ Validation ตามลำดับ โดยเกิดค่าความผันผวนเล็กน้อยในช่วง 2-3 Epochs เมื่อเปรียบเทียบทุกโมเดลแล้ว โมเดลที่ดีที่สุดตามค่าความแม่นยำยังคงเป็น WangchanBERTa ซึ่งมีค่า Validation accuracy สูงสุด

## 3. Evaluation of text classification models

จากขั้นตอนการเตรียมข้อมูล ผู้วิจัยได้แบ่งข้อมูลออกเป็น Train, Validation และ Test set ซึ่ง Train set และ Validation set จะถูกใช้ในส่วนของการทำ Evaluation ด้วยค่า Loss และ Accuracy ในส่วนของชุดข้อมูลสุดท้ายหรือ Test set จะถูกนำมาทำ Evaluation กับ Confusion matrix section และได้ผลลัพธ์ของแต่ละโมเดลดังนี้

Model	Accuracy (Validation)	Loss (Validation)	Accuracy (Test)	Precision (Test)	Recall (Test)	F1-score (Test)
CNN Conv1D	86.80%	29.38%	89.17%	89.26%	89.17%	89.16%
CNN Skip-gram	88.89%	28.77%	88.33%	89.03%	88.33%	88.28%
CNN fastText Skip-gram	88.19%	28.06%	90.00%	91.14%	90.00%	89.93%
BERT	81.00%	40.00%	80.00%	80.00%	80.00%	80.00%
RoBERTa	88.89%	35.20%	90.00%	90.00%	90.00%	90.00%
WangchanBERTa	<b>93.06%</b>	<b>23.85%</b>	<b>93.00%</b>	<b>93.00%</b>	<b>93.00%</b>	<b>92.00%</b>

ผลการทดลองพบว่า WangchanBERTa มีประสิทธิภาพสูงสุดทั้งในด้านการตรวจสอบความถูกต้องและการทดสอบ ในขณะที่ CNN ที่มี Skip-gram โดยใช้ fastText มีความแม่นยำในการทดสอบมากกว่า 90% การโมเดล Pre-trained ขนาดใหญ่สามารถให้ผลลัพธ์ที่ดีขึ้น โดยสรุปแล้ว WangchanBERTa มีประสิทธิภาพดีที่สุดในการบรรดาโมเดลทั้งหมดที่ทำการทดลอง

### Practicality

คณะผู้จัดทำสามารถนำความรู้จากงานวิจัยนี้ เช่น การนำโครงสร้างของโมเดลที่ผู้วิจัยได้ทำการทดลอง มาเป็นต้นแบบในการทำโมเดลของคณะผู้จัดทำ เนื่องจากว่างานวิจัยนี้ใช้ชุดข้อมูลภาษาไทย ซึ่งตรงกับชุดข้อมูลของคณะผู้จัดทำ และยังสามารถนำค่าพารามิเตอร์ต่างๆ มาปรับใช้กับงานของคณะผู้จัดทำได้อีกด้วย อีกทั้งยังมีแหล่งข้อมูลการหาโมเดล Pre-trained ของข้อมูลภาษาไทยที่ทางผู้วิจัยได้ทำการรวบรวมมา เป็นข้อมูลอ้างอิงในการทำงานของคณะผู้จัดทำ

## เอกสาร 2 : Hierarchical Text Classification of Urdu News using Deep

### What is being done?

ปัญหาในเอกสารการวิจัยนี้ คือความท้าทายในการจัดระเบียบข้อมูลอิเล็กทรอนิกส์จำนวนมากให้เป็นหมวดหมู่ที่กำหนดไว้ โดยผู้วิจัยสนใจที่จะนำเทคนิค Text classification มาแก้ปัญหานี้ ผู้วิจัยได้ใช้โมเดลการเรียนรู้เชิงลึกสำหรับการทำ Hierarchical Text classification กับข่าวในภาษาอูรดู (โดยก่อนหน้านี้งานวิจัยนี้ยังไม่เคยมีการใช้ Hierarchical Text classification กับภาษาอูรดู) โดยใช้โมเดล Hierarchical Multi-layer LSTMs (HMLSTM) โมเดลประกอบไปด้วยสองโมดูล คือ Text Representing Layer และ Urdu Hierarchical LSTM Layer (UHLSTML)

### How is it being done?

#### 1. Related Works

ผู้วิจัยได้ศึกษาวิธีการต่าง ๆ ที่จะเพิ่มคุณภาพของผลการจำแนกประเภทในการทำ Hierarchical Text classification และยังทดลองการใช้ Feature engineering ในการทำ Conventional Text classification เพื่อปรับปรุง

ประสิทธิภาพของโมเดล อัลกอริทึมบางส่วนที่ผู้จัดทำได้เลือกและศึกษามาสำหรับการจำแนกข้อความ ได้แก่ SVM, kNN, Naive Bayes และ Decision trees

## 2. The method

ผู้วิจัยจะแนะนำชุดข้อมูลและขั้นตอน Preprocessing จากนั้นทำการทดลองและเปรียบเทียบวิธีการที่ผู้วิจัยใช้กับอัลกอริทึม Machine learning โดยสุดท้ายผู้วิจัยจะวิเคราะห์เกี่ยวกับผลการทดลองข้างทั้งหมด 57566 รายการจะถูกใช้ในการทดลองนี้ ชุดข้อมูล UNDHTC ได้รับการ Label ด้วยตนเอง ซึ่งแบ่งออกเป็นทั้งหมด 12 หมวดหมู่ซึ่งประกอบด้วย 3 หมวดหมู่ใหญ่และ 9 หมวดหมู่ย่อยการแบ่ง Training/Test สำหรับข้อมูล UNDHTC เป็น 80% สำหรับการ Train และ 20% สำหรับการ Test ดังแสดงในรูป

Dataset	Training	Testing	Class/Labels
51325	41060	10265	12

### 1. Preprocessing

ผู้วิจัยได้ใช้วิธีการ Preprocessing เบื้องต้นกับชุดข้อมูล โดยวิธีที่ผู้วิจัยใช้เบื้องต้นคือ ลบข้อมูลที่ไม่จำเป็นในคลังข้อมูล อักขระภาษาอังกฤษ สัญลักษณ์พิเศษ ค่าตัวเลข และ URL จะถูกลบ เพื่อให้ข้อความมีเฉพาะภาษาอูรดูที่เป็นเป้าหมายของผู้วิจัยเท่านั้น โครงสร้างของข้อมูลข้อความได้รับการควบคุมเพื่อปรับปรุงความแม่นยำและประสิทธิภาพของการทดสอบ ขั้นตอนการ Preprocessing ที่ใช้กับชุดข้อมูลมีดังนี้

#### 1.1 Tokenization

นี่เป็นขั้นตอนเริ่มต้นในการ Preprocess ภาษาใดๆ ของ NLP การทำ Tokenization จะแปลงวลีเป็นโทเค็นที่มีค่าหรือนิพจน์เดียว โดยจะแปลงข้อความดิบเป็นแผนภูมิโทเค็น ซึ่งทุกโทเค็นคือคำหนึ่งคำ โทเค็นที่ไม่ถูกต้องอาจส่งผลกระทบต่อผลลัพธ์ของการทดลอง ภาษาอูรดูเป็นเครื่องมือทางภาษาที่ประสบปัญหาที่แตกต่างกันเนื่องจากความไม่สอดคล้องระหว่างการตรวจจับขีดจำกัดของคำศัพท์และประโยค

#### 1.2 Stop Words Removal

ในการลบคำที่ไม่จำเป็น ผู้วิจัยจะใช้ Stop word สำหรับลบคำที่ไม่ค่อยมีความหมายหรือไม่มีความหมาย โดยธรรมชาติภาษาจะประกอบไปด้วยคำที่ไม่มีความหมายและคำที่มีหน้าที่ ในภาษาอูรดู ผู้วิจัยเรียก Stop word ว่า Haroof-e-Jar และในภาษาอังกฤษเรียกว่า คำสันธาน Stop word มักจะถูกตัดออกจากคลังข้อมูลก่อนที่ NLP จะเสร็จสิ้น การนำคำเหล่านี้ออกจะทำให้เราได้ผลลัพธ์ที่ดีขึ้นในงานวิจัย

#### 1.3 Punctuation Removing

ในภาษาอูรดู เครื่องหมายวรรคตอนที่ใช้ส่วนใหญ่คือ '-', '.\_' และ '।' สัญลักษณ์ดังกล่าวมีค่าไม่มากที่จะใช้เป็นคุณลักษณะสำหรับงานจำแนกประเภท ดังนั้นผู้วิจัยจึงลบสัญลักษณ์เหล่านี้ออกโดยใช้นิพจน์ทั่วไป

## 2. Experimental Setup

การทดลองทั้งหมดของผู้วิจัยจะดำเนินการบน Intel Core i7-9750 @2.60GHz พร้อมแรม 16 GB และ GPU GTX 1660ti ซอฟต์แวร์ที่ใช้คือ Jupyter notebook ที่มี Python 3.7.6 ในการทดลอง ผู้วิจัยใช้ word2vec เวอร์ชันสาธารณะซึ่งใช้อัลกอริทึม CBOW เพื่อฝึกการ Embedding 100 คำ โดยมีจำนวนคำขั้นต่ำ 5 คำ ขนาดหน้าต่างตัวกรองคือ 5 พารามิเตอร์ของการฝึกอบรมโมเดลคือ Batch size 32, Drop out 0.5 และ ข้อมูล Training 80% และ 20% สุ่มเลือกสำหรับ Test

## 3. Baselines

ผู้วิจัยจะเปรียบเทียบแนวทางการทำ HMLSTM ที่ผู้วิจัยเลือกมากับวิธีพื้นฐานหลายวิธี เช่น Naïve Bayes, Support Vector Machines (SVM), Decision Tree, Random Forest, K-Nearest Neighbors, Logistic Regression และโมเดลประสาทเชิงลึก เช่น Convolutional Neural Network (CNN)

### 3.1 Gaussian Naïve Bayes

ผู้วิจัยได้ทำการจำแนกหลายประเภทพร้อมกัน โดยมีขั้นตอนที่เกี่ยวข้องดังนี้ แปลงข้อความข่าวภาษาอูรเป็นคำ ใช้ One-Hot Encoding ในการเข้ารหัสคำแล้วทำการ Label ทั้งหมดหมู่ใหญ่และหมวดหมู่ย่อย จากนั้นนำมารวมกันเป็นชุดข้อมูลเดียว ทำการแบ่ง Train set และ Test set แล้วนำอัลกอริทึม GaussianNB มาใช้โดยใช้แบบไบนารีกับพารามิเตอร์ที่ถูกตั้งค่าเริ่มต้นไว้ ทำการทดสอบโดยใช้ไลบรารี skmultilearn

### 3.2 Support Vector Machines (SVMs)

ผู้วิจัยดำเนินการจัดหมวดหมู่ Multi-label โดยใช้ One-Vs-the-Rest (OvR) เนื่องจากผู้วิจัยมีหลาย Label เนื่องจากมีข้อมูลจำนวนมากที่ต้องจัดการ โดยใช้ไลบรารี sklearn

### 3.3 Decision Tree

ผู้วิจัยใช้ Global approach strategy โดยอ่านข้อมูลด้วย Pandas ในขั้นตอนแรกผู้วิจัยจะแปลงข้อความข่าวภาษาอูรเป็นโทเค็น หลังจากนั้นใช้การฝัง word2vec เพื่อเข้ารหัสคำเหล่านั้น Decision Tree และพารามิเตอร์ที่เหลือจะถูกตั้งค่าเป็นค่าเริ่มต้นและทำการทำนาย โดยใช้ไลบรารี sklearn



### 3.4 Random Forest

Random Forest ใช้สำหรับงานจำแนกประเภทแบบ Multi-label ผู้วิจัยจึงสามารถใช้วิธีนี้ในการจำแนกข้อความตัวอักษรภาษาอูรดู โดยปกติแล้ว Random Forest สามารถจัดการข้อมูลที่มีหลากหลายหมวดหมู่ได้อยู่แล้ว ผู้วิจัยได้ทดลองนำวิธีนี้มาใช้ โดยตั้งค่าพารามิเตอร์เป็นค่าเริ่มต้นทั้งหมด แล้วให้โมเดลทำการทำนาย

### 3.5 K-Nearest Neighbors

ผู้วิจัยได้ทำการแปลงข้อมูลและ Label เป็นเวกเตอร์โดยการ Embedding และ Label Encoding จากนั้นแบ่งชุดข้อมูลเป็น Training set และ Test set แล้วใช้ K-Nearest Neighbors ที่ถูกตั้งค่าเริ่มต้นไว้มาทำนายและวัดผล

### 3.6 Logistic Regression

ในวิธีนี้ ผู้วิจัยได้ทำการจำแนกประเภท Multi-label โดยใช้ OvR ใน Scikit-learn แล้วทำการทำนายและวัดผล

### 3.7 Convolutional Neural Network

ผู้วิจัยได้ทำการแปลงข้อความข่าวภาษาอูรดูเป็นโทเค็น จากนั้นใช้การฝัง word2vec เพื่อเข้ารหัสคำนั้นๆ และใช้ CNN กับชุดข้อมูล โดย CNN จะส่ง Kernel ไปยังส่วนที่ถูก Embedding ไว้เพื่อหา Convolutions word โมเดล CNN ที่ผู้วิจัยใช้มีเลเยอร์สองชั้นคือ Convolution และ Softmax นอกจากนี้ผู้วิจัยได้ใช้ ReLU กับ Output ของแต่ละเลเยอร์เพื่อลดการ Overfitting

## 4. Overview

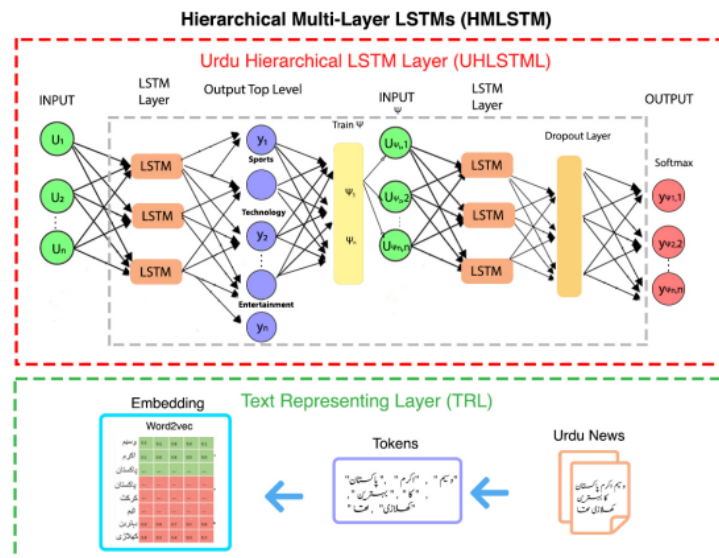


Fig. 8. Hierarchical Multi-Layer LSTMs (HMLSTM)



ผู้วิจัยได้นำเสนอ LSTMs แบบลำดับชั้นหลายชั้น หรือ HMLSTM ดังรูปด้านบน โดยประกอบด้วยสองส่วนคือ Text Representing Layer (TRL) และ Urdu Hierarchical LSTM Layer (UHLSTML) โดยหลักแล้วผู้วิจัยจะใช้ Text Representing Layer เพื่อให้ข้อความข่าวภาษาอูรดูเป็นหนึ่งเดียวกันหรือรวมกัน โดยดูแลระดับบทความและโครงสร้างหมวดหมู่แบบลำดับชั้น (Hierarchical category structure) หลังจากนั้น ผู้วิจัยจะใช้แบบจำลองประสาทเชิงลึก Urdu Hierarchical LSTM Layer (UHLSTML) เพื่อทำนายหมวดหมู่ลำดับชั้นและหมวดหมู่ย่อยของข้อความข่าวภาษาอูรดู

## 5. Text Representing Layer

ในช่วงแรกของแนวทางการทำ HMLSTM จะเน้นไปที่การสร้างข้อความข่าวภาษาอูรดูให้เป็นชุดเดียวกันและรักษาโครงสร้าง Hierarchical (ลำดับชั้นของภาษา) ของภาษาอูรดูไว้ เนื่องจากอัลกอริทึมของ Machine learning ไม่ค่อยมีการใช้กับภาษาอูรดู ข้อความข่าวจึงถูก Encode โดยใช้การทำ Embedding, ในกระบวนการแปลงข้อความข่าวภาษาอูรดูเป็นโทเค็น จะใช้ Hierarchical Category Labels เป็นอินพุต และใช้การฝัง word2vec เพื่อเข้ารหัสข้อความ ในส่วนของ word2vec จะถูกใช้เพื่อแสดงคำในพื้นที่มิติต่ำ ซึ่งคำที่คล้ายกันจะมีเวกเตอร์ที่คล้ายกัน โดยผู้วิจัยจะแปลง Corpus เป็นข้อมูลตัวเลข (จะใช้เป็นอินพุตสำหรับโมเดลในภายหลัง) ข้อความข่าวภาษาอูรดูจะถูกกำหนดเป็นลำดับของคำ ในขณะที่ Label ถูกกำหนดเป็นลำดับของหมวดหมู่ ข้อมูลหมวดหมู่จะถูกแปลงเป็นข้อมูลตัวเลขโดยการ Label encoding เพื่อให้โมเดล UHLSTML สามารถเข้าใจ Label ได้ดีขึ้น Label จะถูกแปลงเป็นเมทริกซ์ไบนารีโดยใช้การเข้ารหัสแบบ one-hot โดยการใช้ไลบรารี Keras ของ TensorFlow เพื่อทำการแปลง ในช่วงท้ายข้อมูลจะถูกนำมารวมกันระหว่างข้อความข่าวภาษาอูรดูในแต่ละรายการ และ Hierarchical Category Labels จากนั้นก็จะพร้อมที่จะป้อนเข้าสู่โมเดล UHLSTML

## 6. Urdu Hierarchical LSTM Layer

เลเยอร์ Urdu Hierarchical LSTM จะขึ้นอยู่กับ Hierarchically-Structured Local Classifiers ที่มีโครงสร้างแบบลำดับชั้น ในวิธีนี้ ผู้วิจัยฝึกเลเยอร์ LSTM หนึ่งเลเยอร์สำหรับในแต่ละระดับของลำดับชั้นของหมวดหมู่

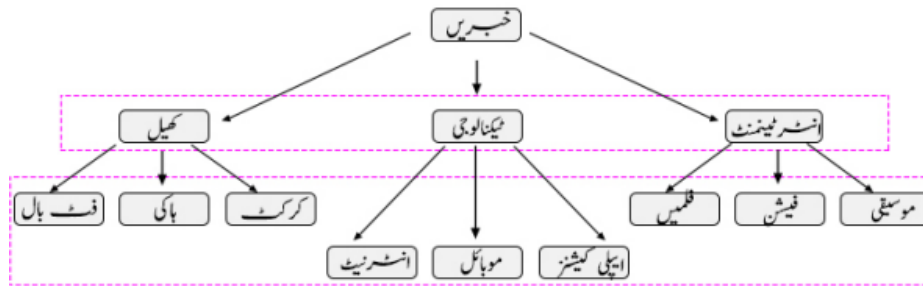



Fig. 9. LSTM layer per level (each dashed rectangle represents a LSTM layer).

หลังจากการแสดงความหมายและ Label ของข่าวภาษาอูรดูแล้ว แบบจำลอง UHLSTML ที่ผู้วิจัยเลือกมา จะถูกนำมาใช้ โดยที่ UHLSTML เป็นเครือข่าย LSTM เชิงลึกที่เชื่อมต่อแบบ end-to-end ซึ่งออกแบบมาเพื่อการเรียนรู้คุณลักษณะโดยอัตโนมัติ โมเดลนี้ใช้สถาปัตยกรรมเครือข่ายประสาทแบบวนซ้ำ โดยสถาปัตยกรรมของเครือข่ายที่กล่าวมา ประกอบด้วยเลเยอร์ LSTM สองชั้น ดังรูปด้านล่าง



โมเดลด้านบนประกอบด้วยเลเยอร์ LSTM สองชั้นสำหรับการจำแนกตามลำดับชั้น (Hierarchical classification) เลเยอร์ LSTM แรกจะเรียนรู้คุณลักษณะสำหรับการจำแนกหมวดหมู่หลัก และเอาต์พุตจะถูกส่งผ่านไปยังเลเยอร์ LSTM ที่สอง ชั้นที่สองจะใช้ในการจัดประเภทหมวดหมู่หลักที่ได้รับการ Train ตัวอย่างเช่น หาก LSTM แรกระบุหมวดหมู่เป็นกีฬา LSTM ที่สองจะเน้นเฉพาะข่าวที่เกี่ยวข้องกับกีฬา LSTM ในโมเดลนี้จะมีการใช้ ReLU, มีเลเยอร์เอาต์พุตเป็น softmax, มีการใช้ backpropagation โดยใช้ Adam Optimizer (Learning rate 0.001) และ cross-entropy loss และเลเยอร์ dropout เป็นเลเยอร์สุดท้ายเพื่อลดการ Overfitting

**What is the dataset?**

Sub Categories	Categories
کرکٹ ہاکی فٹ بال	کھیل
انسٹریٹ اپلی کیشنز موبائل	ٹیکنالوجی
فلمیں موسیقی فیشن	انسٹرٹینمنٹ

Fig. 11. Urdu-News-Dataset-for-Hierarchical-Text-Classification

ชุดข้อมูลข่าวภาษาอูรดูขนาดใหญ่ (เก็บข้อมูลจากเว็บไซต์ Pakistani urdu news, Urdupoint, Express news, Dawn news, BBC Urdu, ARYnews, BOL news and Hum news) สำหรับการทำให้ Hierarchical Text classification ซึ่งมีชื่อว่า Urdu News Dataset for Hierarchical Text Classification (UNDHTC) ชุดข้อมูลนี้ประกอบด้วย 51,325 ประโยคจากเว็บไซต์ข่าวออนไลน์ 8 แห่งที่อยู่ในประเภทดังต่อไปนี้ กีฬา, เทคโนโลยี, และความบันเทิง และแบ่งออกเป็นหมวดหมู่ย่อย ได้แก่ คริกเก็ต, ฮอกกี, ฟุตบอล, แอปพลิเคชัน, โทรศัพท์มือถือ, อินเทอร์เน็ต, ดนตรี, แฟชั่น, และภาพยนตร์

Table 1. Dataset Statics

Dataset Statistics	
Total News	299815
Cleaned	57566
Labeled	51325

Table 2. Dataset Stats in Detail

Category	Sub Category	Number of documents	Total
Sports	Cricket	12431	20002
	Hockey	2011	
	Football	5560	
Technology	Internet	1735	16208
	Applications	3742	
	Mobile	10731	
Entertainment	Movies	3902	15115
	Music	2552	
	Fashion	8661	

## Evaluation metric

การประเมินประสิทธิภาพของอัลกอริทึม ผู้วิจัยได้ใช้เมตริกการประเมินทั้งหมดสามแบบ ได้แก่ Precision, Recall, และ F1 score (รวมไปถึง Micro-F1 และ Macro-F1 ด้วย) นอกจากนี้ผู้วิจัยยังใช้ Classification Accuracy หรือ term accuracy อีกด้วย ให้  $TP_l$ ,  $FP_l$ ,  $FN_l$  เป็นจำนวนของ True positives, False positives, และ False negatives สำหรับ l-th label ในหมวดหมู่ C ตามลำดับ ดังนั้นสมการของ Micro-F1 คือ

$$P = \frac{\sum_{l \in C} TP_l}{\sum_{l \in C} TP_l + FP_l}, R = \frac{\sum_{l \in C} TP_l}{\sum_{l \in C} TP_l + FN_l}, F1_{Micro} = \frac{2PR}{P + R}$$

สมการสำหรับ Macro-F1 จะถูกกำหนดเป็นดังนี้

$$P_l = \frac{TP_l}{TP_l + FP_l}, R_l = \frac{TP_l}{TP_l + FN_l}, F1_{Macro} = \frac{1}{|C|} \sum_{l \in C} \frac{2P_l R_l}{P_l + R_l}$$

เพื่อแสดงให้เห็นความสำคัญของกระบวนการและโมเดลที่ผู้วิจัยนำมาใช้ ผู้วิจัยจะเปรียบเทียบกับ HMLSTM กับ Baselines ทั้งหมด การทดลองจะถูกดำเนินการกับชุดข้อมูลข่าวภาษาอูรดู (UNDHTC) แสดงให้เห็นว่าแนวทางที่ผู้วิจัยเสนอมาหรือ Hierarchical Multi-Layer LSTMs (HMLSTM) มีประสิทธิภาพดีกว่าโมเดล Machine learning

Methods	#Classes	Accuracy	Precision	Recall	Macro-F1	Micro-F1
Gaussian Naïve Bayes	12	0.4744	0.4223	0.8693	0.5257	0.6987
Support Vector Machines	12	0.7711	0.7434	0.7769	0.7590	0.8878
Decision Tree	12	0.7285	0.6113	0.6092	0.6102	0.7949
Random Forest	12	0.7959	0.9256	0.6331	0.7391	0.8806
K-Nearest Neighbors	12	0.5989	0.6300	0.5668	0.5467	0.6940
Logistic Regression	12	0.7962	0.7875	0.7822	0.7848	0.8980
CNN	12	0.8740	0.8866	0.8496	0.8632	0.9323
HMLSTM	12	<b>0.9402</b>	<b>0.9259</b>	<b>0.8812</b>	<b>0.8927</b>	<b>0.9683</b>

จากตารางด้านบน โมเดล CNN ทำงานได้ดี และให้ผลลัพธ์ที่ดีเมื่อเปรียบเทียบกับวิธีการสำหรับอัลกอริทึมการจัดประเภทข้อความแบบเก่า ผู้วิจัยพบว่า Logistic Regression ที่ใช้ OvR และการตั้งค่าพารามิเตอร์เป็นค่าเริ่มต้นนั้นมีประสิทธิภาพดีกว่าโมเดลอื่นๆ จากนั้นก็มี Support Vector Machines และ LR ซึ่งทำงานได้ดีกว่าอัลกอริทึมที่ตัวอื่นๆ SVM นั้นดีในการจำแนกพวก Multi-label ในขณะที่ K nearest neighbor ให้ผลลัพธ์ที่ไม่ค่อยดีในชุดข่าวภาษาอูรดู โดยการแยก Label ตามระดับข้อมูล จากตารางด้านบนที่ระบุความผันแปรของ Macro-F1 ระหว่างโมเดลพื้นฐาน กับ HMLSTM พบว่า HMLSTM ให้ผลลัพธ์ที่ดีที่สุดในตัวชี้วัดการประเมินทั้งหมด ซึ่งแสดงว่า HMLSTM มีความสามารถมากกว่าสำหรับการทำ Multi-label




Fig. 16. Hierarchical Multi-Layer LSTMs (HMLSTM) Results

### Practicality

คณะผู้จัดทำสามารถนำโมเดลต่างๆ มาใช้กับงานของคณะผู้จัดทำได้ โดยใช้การเปรียบเทียบผลลัพธ์จากเอกสารการวิจัยนี้ มาเป็นตัวเลือกเบื้องต้น เนื่องจากเอกสารการวิจัยนี้เป็นการทำ Text classification เช่นเดียวกับเป้าหมายของผู้จัดทำที่ต้องการทำ classification แยกทั้งหมดหมู่หลักและหมวดหมู่ย่อย นอกจากนี้คณะผู้จัดทำยังสามารถนำขั้นตอนการ Preprocessing มาปรับใช้กับงานของคณะผู้จัดทำได้ เนื่องจากในหลายๆ ภาษา มีขั้นตอนการ Preprocessing ใกล้เคียงกัน จะมีส่วนที่ต่างกันเช่น การทำ Tokenization หรือ Stop word เป็นต้น

## เอกสาร 3 : Bengali Text Categorization Based on Deep Hybrid CNN–LSTM Network with Word Embedding (26-27 February 2022)

### - What is being done? What is the research question?

เอกสารการวิจัยนี้มีเป้าหมายเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำการจัดหมวดหมู่คำกับข้อมูลจากหนังสือพิมพ์ Bangla โดยผู้วิจัยออกแบบการทดลองโดยใช้อัลกอริทึมที่มีอยู่ในปัจจุบันนำมาประยุกต์ใช้ในโมเดลทั้งหมดดังนี้คือ Artificial Neural Network (ANN), Recurrent neural networks (RNN), Convolutional Neural Network (CNN), Hybrid (CNN-LSTM)

### - How is it being done?

#### - How is it different from previous work? What had been done?

1. เอกสารการวิจัยนี้ อ้างอิงจากงานวิจัย Tudu et al. ทำการออกแบบการทดลองเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำการจัดหมวดหมู่คำกับข้อมูลจากหนังสือพิมพ์ Bangla โดยทางคณะผู้ทดลองได้นำข้อมูลจำนวน 84,906 คำและประกอบไปด้วย 10 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์ และทำการทดลองตัวโมเดลทั้งหมด 4 โมเดลดังนี้ 1.Support Vector Machine (SVM) 2.Multinomial Naive Bayes (MNB) 3.Stochastic Gradient Descent (SGD) 4.Logistic Regression (LR) จากผลการทดลองโมเดล โมเดลที่มีความแม่นยำสูงที่สุดคือ โมเดล Support Vector Machine (SVM) ได้ค่าความแม่นยำ 87.5%

2. เอกสารการวิจัยนี้ อ้างอิงจากงานวิจัย Chowdhury et al. ทำการออกแบบการทดลองเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำการจัดหมวดหมู่คำกับข้อมูลจากหนังสือพิมพ์ Kaggle โดยทางคณะผู้ทดลองได้นำข้อมูลจำนวน 140,000 คำและประกอบไปด้วย 10 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์ ผู้ทดลองได้มีการประยุกต์ใช้เมทริกซ์ GloVe ผสมกับการทำการทดลองตัวโมเดลทั้งหมด 2 โมเดลดังนี้ 1.LSTM 2.CNN จากผลการทดลองโมเดล โมเดลที่มีความแม่นยำสูงที่สุดคือ โมเดลที่ประยุกต์ใช้เมทริกซ์ GloVe ได้ค่าความแม่นยำ 87% แต่ถ้าโมเดลที่ไม่ประยุกต์ใช้เมทริกซ์ GloVe ได้ค่าความแม่นยำ 79%
3. เอกสารการวิจัยนี้ อ้างอิงจากงานวิจัย Chakraborty et al. ทำการออกแบบการทดลองเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำการจัดหมวดหมู่คำกับข้อมูลจากหนังสือพิมพ์ทางอินเทอร์เน็ต โดยทางคณะผู้ทดลองได้นำข้อมูลจาก 1600 บทความและประกอบไปด้วย 16 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์แต่ละหมวดหมู่จะประกอบไปด้วย 100 บทความผู้ทดลองได้มีการประยุกต์ใช้ TF-IDF กับการทำการทดลองตัวโมเดลทั้ง 2 โมเดลดังนี้ 1.Machine Learning Classifier 2.Neural Networks จากผลการทดลองโมเดล โมเดลมีความแม่นยำสูง 84.58% เมื่อเปรียบเทียบกับโมเดลประเภทอื่น

#### - What is the method?

เอกสารการวิจัยนี้ทางคณะผู้จัดทำได้ทำการออกแบบการทดลองเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดในการทำการจัดหมวดหมู่คำกับข้อมูลจากหนังสือพิมพ์ Bangla โดยจะประกอบด้วยขั้นตอนดังต่อไปนี้

1. ชุดข้อมูลที่น่ามาเรียนรู้จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 95853 คำและ 12 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์โดยแต่ละหมวดหมู่คือ 1.อุบัติเหตุ 2.ศิลปะ 3.ฆาตกรรม 4.การเงิน 5.การศึกษา 6.ความบันเทิง 7.สิ่งแวดล้อม 8.ต่างประเทศ 9.ความคิด 10.การเมือง 11.วิทยาศาสตร์และเทคโนโลยี 12.กีฬา
2. ข้อมูลที่น่ามาเรียนรู้จะมีอักษรหรืออักขระพิเศษที่ไม่จำเป็นและช่องว่างระหว่างประโยคและคำศัพท์ที่มีความหมายเหมือนกันแต่เขียนคนละรูปและอีโมจิสำหรับการเรียนรู้ข้อมูล ดังนั้นการเรียนรู้ข้อมูลที่มีประสิทธิภาพจะต้องตัดข้อมูลที่ไม่จำเป็นออก
3. การแบ่งข้อมูลสำหรับการเรียนรู้และการทดสอบโมเดล โดยจะแบ่งเป็นอัตราส่วนระหว่างเรียนรู้และทดสอบด้วยอัตราส่วน 0.8 : 0.2 จากข้อมูลทั้งหมด
4. การดึงคุณสมบัติพิเศษของคำโดยการแปลงคำให้อยู่ในรูปของเมทริกซ์
5. เมื่อได้ข้อมูลที่อยู่ในรูปของเมทริกซ์ คณะผู้จัดทำได้ทำการทดลองโดยการเรียนรู้กับโมเดลทั้ง 4 ชนิดดังนี้ 1.Artificial Neural Network (ANN) 2.Recurrent neural networks (RNN) 3.Convolutional Neural Network (CNN) 4.Hybrid (CNN-LSTM) โดยเป้าหมายคือหาโมเดลที่มีประสิทธิภาพดีที่สุดจากคะแนน Accuracy, Precision, Recall และ F1-Score
6. โมเดลที่มีความแม่นยำมากที่สุดจากการทดลอง นำไปเปรียบเทียบกับความแม่นยำกับเอกสารการวิจัยที่มีการหาโมเดลที่มีประสิทธิภาพในการทำการจัดหมวดหมู่คำกับข้อมูลจาก

หนังสือพิมพ์ Bangla จากในเอกสารการวิจัยที่มีความเกี่ยวข้องกับเอกสารวิจัยนี้และมีมาก่อนหน้านี้

- **What is the dataset?**

- **Nature of dataset**

ชุดข้อมูลที่นำมาเรียนรู้จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 95853 คำและ 12 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์โดยแต่ละหมวดหมู่คือ 1.อุบัติเหตุ 2. ศิลปะ 3.ฆาตกรรม 4.การเงิน 5.การศึกษา 6.ความบันเทิง 7.สิ่งแวดล้อม 8.ต่างประเทศ 9.ความคิด 10.การเมือง 11.วิทยาศาสตร์และเทคโนโลยี 12.กีฬา ดังนี้

หมวดหมู่ตามหัวข้อของหนังสือพิมพ์	จำนวนข้อมูล
อุบัติเหตุ	6126
ศิลปะ	2170
ฆาตกรรม	8199
การเงิน	3389
การศึกษา	10706
ความบันเทิง	8951
สิ่งแวดล้อม	3754
ต่างประเทศ	5036
ความคิด	7684
การเมือง	18558
วิทยาศาสตร์และเทคโนโลยี	2810
กีฬา	11296

- **How many training/testing samples? How many classes/vocab size ?**

การทดลองเปรียบเทียบโมเดลทั้ง 4 ชนิดดังนี้ 1.Artificial Neural Network (ANN) 2.Recurrent neural networks (RNN) 3.Convolutional Neural Network (CNN) 4.Hybrid (CNN-LSTM) โดยข้อมูลที่ใช้จะเป็นชุดข้อมูลที่นำมาเรียนรู้จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 95853 คำและ 12 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์



ข้อมูลจะแบ่งระหว่างข้อมูลที่จะนำมาเรียนรู้และข้อมูลที่จะนำมาทดสอบแบ่งด้วยอัตราส่วน 0.8 : 0.2 โดยข้อมูลแต่ละประเภทจะมีจำนวนดังนี้  
จำนวนข้อมูลใช้สำหรับการเรียนรู้โมเดล

หมวดหมู่ตามหัวข้อของหนังสือพิมพ์	จำนวนข้อมูล
อุบัติเหตุ	4901
ศิลปะ	1736
ฆาตกรรม	6560
การเงิน	2712
การศึกษา	8565
ความบันเทิง	7161
สิ่งแวดล้อม	3004
ต่างประเทศ	4029
ความคิด	6148
การเมือง	14847
วิทยาศาสตร์และเทคโนโลยี	2248
กีฬา	9037

จำนวนข้อมูลใช้สำหรับการทดสอบโมเดล

หมวดหมู่ตามหัวข้อของหนังสือพิมพ์	จำนวนข้อมูล
อุบัติเหตุ	1225
ศิลปะ	434
ฆาตกรรม	1639
การเงิน	677
การศึกษา	2141

ความบันเทิง	1790
สิ่งแวดล้อม	750
ต่างประเทศ	1007
ความคิด	1536
การเมือง	3711
วิทยาศาสตร์และเทคโนโลยี	562
กีฬา	2259

เอกสารการวิจัยของคณะผู้ทดลองของทูดูและทูดูการทดลองเปรียบเทียบโมเดลทั้ง 4 ชนิด ดังนี้ 1.Support Vector Machine (SVM) 2.Multinomial Naive Bayes (MNB) 3. Stochastic Gradient Descent (SGD) 4.Logistic Regression (LR) โดยข้อมูลที่ใช้จะเป็นชุดข้อมูลที่นำมาเรียนรู้ จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 84906 คำและ 10 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์ ข้อมูลจะถูกระหว่างข้อมูลที่จะนำมาเรียนรู้และข้อมูลที่จะนำมาทดสอบแบ่งด้วยอัตราส่วน 0.8 : 0.2 โดยข้อมูลแต่ละประเภทจะมีจำนวนดังนี้ จำนวนข้อมูลใช้สำหรับการเรียนรู้โมเดล

หมวดหมู่ตามหัวข้อของหนังสือพิมพ์	จำนวนข้อมูล
อุบัติเหตุ	4901
ฆาตกรรม	6560
การเงิน	2712
การศึกษา	8565
ความบันเทิง	7161
สิ่งแวดล้อม	3004
ต่างประเทศ	4029
การเมือง	14847
วิทยาศาสตร์และเทคโนโลยี	2248
กีฬา	9037

## จำนวนข้อมูลใช้สำหรับการทดสอบโมเดล


หมวดหมู่ตามหัวข้อของหนังสือพิมพ์	จำนวนข้อมูล
อุบัติเหตุ	1225
ฆาตกรรม	1639
การเงิน	677
การศึกษา	2141
ความบันเทิง	1790
สิ่งแวดล้อม	750
ต่างประเทศ	1007
การเมือง	3711
วิทยาศาสตร์และเทคโนโลยี	562
กีฬา	2259

### - Evaluation Metric

#### - What are the baselines?


ทางคณะผู้จัดทำ ออกแบบการวัดผลการทดลองทั้งหมด 3 ประเภทดังนี้

1.คณะผู้จัดทำออกแบบการทดลองโดยเปรียบเทียบโมเดลทั้ง 4 ชนิดคือ 1.Artificial Neural Network (ANN) 2.Recurrent neural networks (RNN) 3.Convolutional Neural Network (CNN) 4.Hybrid (CNN-LSTM) โดยข้อมูลที่ใช้จะเป็นชุดข้อมูลที่นำมาเรียนรู้จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 95853 คำและ 12 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์



จากผลการทดลองเปรียบเทียบโมเดลทั้ง 4 ชนิด โมเดล Hybrid (CNN-LSTM) มีค่าความแม่นยำสูงที่สุดมีความแม่นยำ 84.93% และโมเดล Artificial Neural Network (ANN) มีค่าความแม่นยำน้อยที่สุดมีความแม่นยำ 80.10% โมเดลที่มีประสิทธิภาพสูงสุดคือ Hybrid(CNN-LSTM) เพราะประกอบด้วยโมเดล 2 ประเภทที่ประกอบกันคือ CNN และ LSTM โดยหน้าที่ของโมเดล CNN คือ แยกความสำคัญคุณสมบัติจากข้อมูลข้อมูลที่นำมาเรียนรู้ และมีประสิทธิภาพสูงกับจำนวนข้อมูลที่น้อย และ LSTM คือ แยกเนื้อหาและเรียนรู้จากคุณสมบัติที่มาจากโมเดล CNN

2.คณะผู้จัดทำออกแบบการทดลองโดยเปรียบเทียบเอกสารการวิจัยที่มีความเกี่ยวข้องในอดีตคือ เอกสารการวิจัยของคณะผู้ทดลองของทูดูและทูดูการทดลองเปรียบเทียบโมเดลทั้ง 4 ชนิด ดังนี้ 1.Support Vector Machine (SVM) 2.Multinomial Naive Bayes (MNB) 3. Stochastic Gradient Descent (SGD) 4.Logistic Regression (LR) โดยข้อมูลที่ใช้จะเป็นชุดข้อมูลที่นำมาเรียนรู้ จะเป็นชุดข้อมูลจากหนังสือพิมพ์ Bangla ประกอบไปด้วยข้อมูลจำนวน 84906 คำและ 10 หมวดหมู่ตามหัวข้อของหนังสือพิมพ์



จากผลการทดลองเปรียบเทียบโมเดลที่มีประสิทธิภาพสูงสุดจากการทดลองกับโมเดลที่มีประสิทธิภาพสูงสุดจากเอกสารการวิจัยที่เกี่ยวข้องที่มีการทดลองในอดีต พบว่าโมเดลที่มีความแม่นยำที่สุดคือ โมเดล Hybrid (CNN-LSTM) ความแม่นยำ 88.56% และโมเดล Support Vector Machine (SVM) มีความแม่นยำที่น้อยกว่ามีความแม่นยำ 87.50% โดยโมเดล Support Vector Machine (SVM) มีการประยุกต์ใช้ Word Embedding เพื่อประสิทธิภาพที่สูงสุดแต่ความแม่นยำยังน้อยกว่าโมเดล Hybrid (CNN-LSTM)

3. คณะผู้จัดทำวัดประสิทธิภาพของแบบจำลองโมเดลทั้ง 4 ชนิดคือ 1.Artificial Neural Network (ANN) 2.Recurrent neural networks (RNN) 3.Convolutional Neural Network (CNN) 4.Hybrid (CNN-LSTM) โดยใช้ข้อมูลเดียวกันกับการทดลองที่ 1 ผลลัพธ์ที่ได้จะเป็นค่า Precision, Recall, F1-score และ Accuracy โดยคิดจากค่าของ True Positive, False Positive, True Negative และ False Negative จากสมการ

$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

ผลลัพธ์ที่ได้จากโมเดลทั้ง 4 ประเภท

Models	Precision	Recall	F1-score
Hybrid	0.85	0.85	0.85
CNN	0.83	0.83	0.83
ANN	0.79	0.80	0.80
LSTM	0.81	0.81	0.81

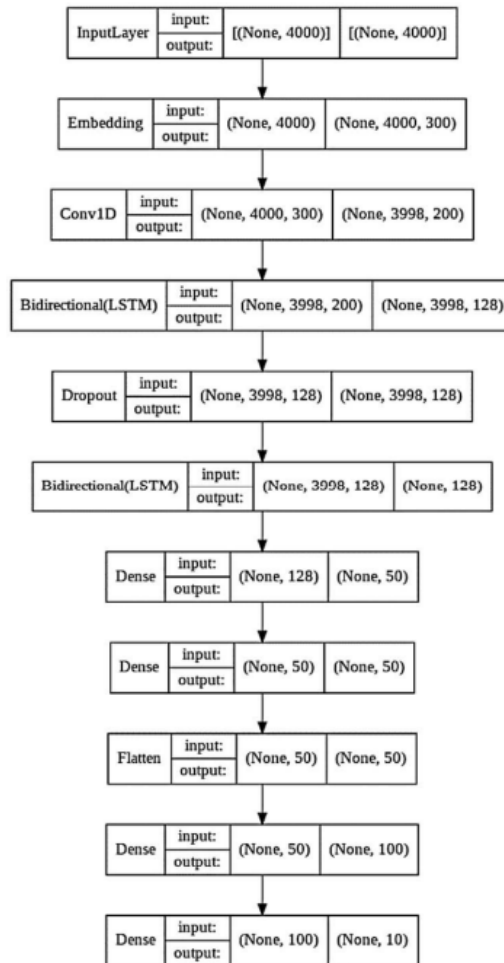
ผลการทดลองพบว่า Hybrid(CNN-LSTM) มีประสิทธิภาพสูงสุดทั้งในด้านการตรวจสอบความถูกต้องและการทดสอบ ในขณะที่ CNN มีความแม่นยำในการทดสอบมากกว่า 83% การประยุกต์ใช้โมเดล CNN กับจำนวนข้อมูลที่น้อยสามารถให้ผลลัพธ์ที่ดีขึ้น โดยสรุปแล้ว Hybrid(CNN-LSTM) มีประสิทธิภาพดีที่สุดในบรรดาโมเดลทั้งหมดที่ทำการทดลองเนื่องจากข้อมูลที่น้อย

#### - Practicality

##### - Prone to parameter tuning?

เอกสารการวิจัยนี้ ทางคณะผู้จัดทำออกแบบการปรับแต่งพารามิเตอร์เพื่อหาโมเดลที่มีประสิทธิภาพสูงสุด คณะผู้จัดทำได้ทดลอง 3 ครั้งเพื่อหาความแตกต่างของค่า Precision, Recall, F1-score และ Accuracy และได้สรุปค่าพารามิเตอร์ที่มีประสิทธิภาพสูงสุดดังนี้

<u>LSTM-CNN Hybrid:</u> Embedding= [300,400,500], Conv1d= [100,200,300], Maxpooling1d= [2], Bi-LSTM Layers= [2,3], Bi-LSTM Units= [64,128], Learning rate= [0.005,0.0005,0.00005], Batch size= [64,128,256], Regularizer= [L2], Optimizer= [RMSprop,Adam]	Embedding= [400] Conv1d= [200], Maxpooling1d= [2], Bi-LSTM Layers= [2], Bi-LSTM Units= [64], Learning rate= [0.0005], Batch size= [128], Regularizer= [L2], Optimizer= [Adam]
--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------



## Practicality

คณะผู้จัดทำสามารถนำความรู้จากงานวิจัยนี้ เช่น การนำโครงสร้างของโมเดลที่ผู้วิจัยได้ทำการทดลอง มาเป็นต้นแบบในการทำโมเดลของคณะผู้จัดทำ เนื่องจากว่างานวิจัยนี้มีชุดข้อมูลที่น่าสนใจ โดยมัลักษณะตรงกับชุดข้อมูลของคณะผู้จัดทำที่น้อย เนื่องจากชุดข้อมูลของผู้จัดทำมีการสร้างออกแบบและเก็บข้อมูลด้วยทางคณะผู้จัดทำ และยังสามารถประยุกต์ใช้ค่าพารามิเตอร์ต่างๆ มาปรับใช้กับงานของคณะผู้จัดทำได้อีกด้วย อีกทั้งยังมีแหล่งข้อมูลในการสร้างโมเดล Hybrid (CNN-LSTM) ที่มีประสิทธิภาพที่ดีกับข้อมูลที่น้อย การวิจัยนี้สามารถเป็นข้อมูลอ้างอิงในการทำงานของคณะผู้จัดทำได้

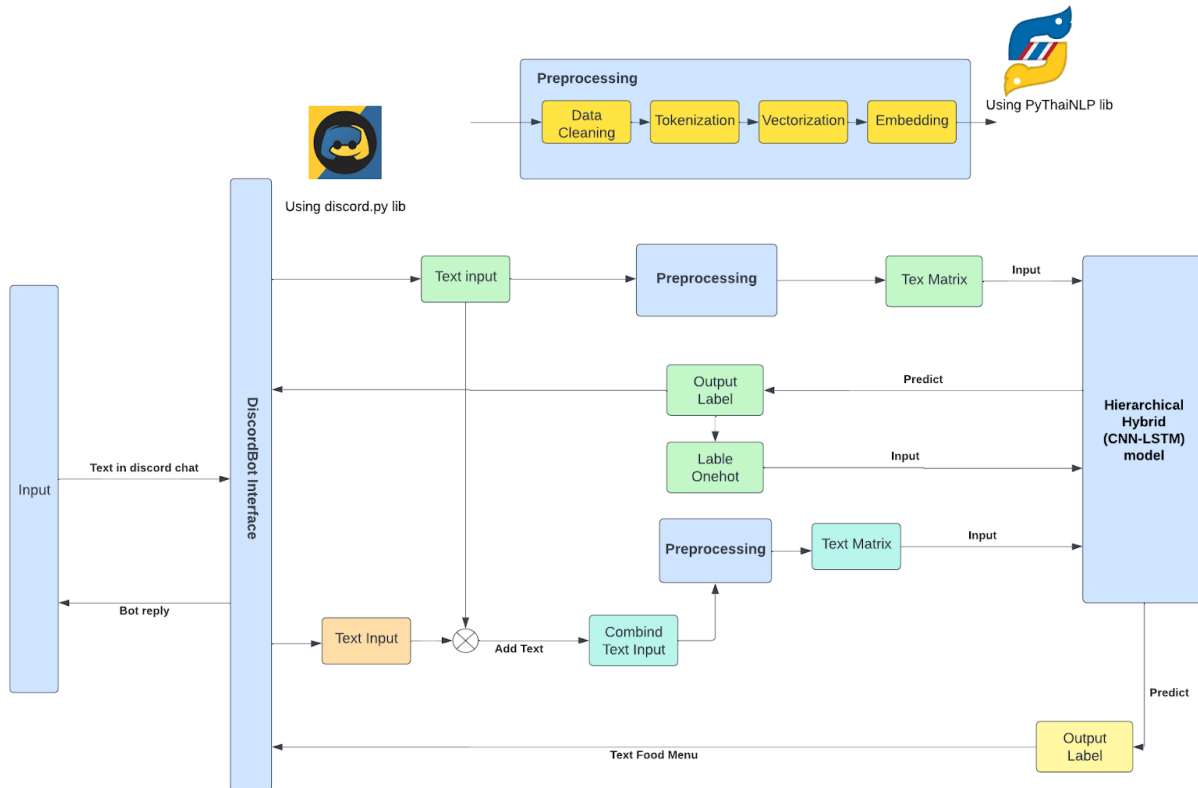
## Method

## Process

คณะผู้จัดทำได้ออกแบบขั้นตอนการสร้างโมเดลที่มีประสิทธิภาพสูงสุดโดยมีวัตถุประสงค์การออกแบบโมเดลที่มีประสิทธิภาพเมื่อรับข้อมูลเป็นความต้องการของผู้ใช้งาน โดยผู้ใช้งานจะให้



ข้อมูลเป็นประโยคคำถามหรือประโยคที่ไม่บ่งบอกเอกลักษณ์และลักษณะของอาหารที่ผู้ใช้งานต้องการโดยจะไม่บอกชัดเจน โมเดลจะทำนายอาหารที่ผู้ใช้งานต้องการ โดยจะมีผังงานการทำงานของผู้ใช้งานกับโมเดลดังรูปภาพนี้



จากผังงานการทำงานของผู้ใช้งานกับโมเดลเราจะแบ่งขั้นตอนการทำงานออกเป็นทั้งหมด 5 ขั้นตอนในการสร้างโมเดลดังนี้

## 1. Dataset :

ชุดข้อมูลนี้เป็นชุดข้อมูลอธิบายถึงรสชาติ คุณลักษณะ ขั้นตอนการทำ รูปร่าง วัฒนธรรมหรือประวัติศาสตร์ สารอาหาร และส่วนผสมของอาหาร โดยประกอบด้วย 576 ประโยค 13088 คำและมี 3 หมวดหมู่ตามประเภทของอาหารคือ 1.พิซซ่า 2.สปาเก็ตตี้ 3.ก๋วยเตี๋ยว แต่ละประเภทของอาหารแบ่งออกเป็นอาหารทั้ง 4 ชนิดคือ 1.พิซซ่าจะประกอบไปด้วย 1.1.ค็อกเทลกุ้ง 1.2.มีทเคอูลุกซ์ 1.3.เห็ดและมะเขือเทศ 1.4.ดิปเปอร์ คลาสสิก 2.ก๋วยเตี๋ยวจะประกอบไปด้วย 2.1.ก๋วยเตี๋ยวน้ำตก 2.2.ก๋วยเตี๋ยวมั้ยี่น้ำใส 2.3.บะหมี่แห้งน้ำ-หมูแดง-หมูกรอบ 2.4.เกาเหลา 3.สปาเก็ตตี้จะประกอบไปด้วย 3.1.สปาเก็ตตี้มีทบอล 3.2.สปาเก็ตตี้คาโบนาร่า 3.3.สปาเก็ตตี้ผัก 3.4.สปาเก็ตตี้ทะเล

## 2. Data Preprocessing :

คณะผู้จัดทำมีความจำเป็นในการกำจัดข้อมูลที่ไม่มีความเกี่ยวข้องและข้อมูลที่เกินความจำเป็นของชุดข้อมูล โดยถ้าไม่กำจัดข้อมูลที่ไม่เกี่ยวข้องจะทำให้เกิดผลกระทบต่อการดึงคุณสมบัติ

หรือลักษณะเฉพาะจากชุดข้อมูล ดังนั้นทางคณะผู้จัดทำต้องกำจัดข้อมูลที่ไม่มีความเกี่ยวเพื่อเพิ่มประสิทธิภาพของโมเดล มีขั้นตอนการกำจัดข้อมูลที่ไม่เกี่ยวข้องดังต่อไปนี้

### 2.1.กำจัดข้อมูลที่มีการซ้ำกัน

คณะผู้จัดทำกำจัดข้อมูลที่มีการซ้ำกัน เนื่องจากชุดข้อมูลในการเรียนรู้ต้องการข้อมูลที่จะบ่งบอกถึงลักษณะพิเศษของชุดข้อมูลเพื่อง่ายสำหรับการเรียนรู้ของโมเดล เนื่องจากถ้าโมเดลมีการเรียนรู้ชุดข้อมูลที่เกินความจำเป็น มีผลกระทบให้ค่าน้ำหนักของข้อมูลในโมเดลระหว่างการเรียนรู้มีค่าที่ลดลงและทำให้ประสิทธิภาพของโมเดลลดลง

### 2.2.กำจัดช่องว่างที่ไม่จำเป็นสำหรับข้างหน้าและข้างหลังประโยค

คณะผู้จัดทำกำจัดช่องว่างทั้งหมดทั้งข้างหน้าและข้างหลังในชุดข้อมูลเพื่อกำจัดข้อมูลที่ไม่มีความหมายที่บ่งบอกข้อมูลเกี่ยวกับอาหารสำหรับการเรียนรู้

### 2.3.กำจัดช่องว่างระหว่างคำ

คณะผู้จัดทำกำจัดช่องว่างระหว่างคำทั้งหมดในชุดข้อมูลเพื่อกำจัดข้อมูลที่ไม่มีความหมายที่บ่งบอกข้อมูลเกี่ยวกับอาหารสำหรับการเรียนรู้

### 2.4.กำจัดอักขระและอักขรพิเศษที่ไม่เกี่ยวข้อง

ตัวอักษรบางตัวที่ไม่มีความหมายหรือความจำเป็นสำหรับการเรียนรู้ยกตัวอย่างเช่น ! "#\$%&'()\*+,-./:;<=>?@[\\]^\_`{|}~ๆ ดังนั้นทางคณะผู้จัดทำจำเป็นต้องกำจัดอักขระหรืออักขรบางตัวที่ไม่มีความจำเป็นในชุดข้อมูล

## 3. Split Dataset :

ชุดข้อมูลนี้เป็นชุดข้อมูลอธิบายถึงรสชาติ คุณลักษณะ ขั้นตอนการทำ รูปร่าง วัฒนธรรมหรือประวัติศาสตร์ สารอาหาร และส่วนผสมของอาหารโดยประกอบด้วย 576 ประโยค 13088 คำและมี 3 หมวดหมู่ตามประเภทของอาหาร แต่ละประเภทของอาหารแบ่งออกเป็นอาหารทั้ง 4 ชนิด โดยข้อมูลจะแบ่งระหว่างข้อมูลที่จะนำมาเรียนรู้และข้อมูลที่จะนำมาทดสอบแบ่งด้วยอัตราส่วน 0.8 : 0.2 จากข้อมูลทั้งหมด

## 4. Feature Extraction :

### 4.1.Label Mapping :

คณะผู้จัดทำต้องการกำหนดชุดข้อมูลที่รับเข้ามาที่บ่งบอกถึงประเภทของอาหารและชนิดของอาหารในรูปแบบของตัวเลขเพื่อเหมาะสำหรับการนำไปประยุกต์ใช้ในโมเดล โดยโมเดลจะเรียนรู้แค่ชุดข้อมูลอธิบายถึงรสชาติ คุณลักษณะ ขั้นตอนการทำ รูปร่าง วัฒนธรรมหรือประวัติศาสตร์ สารอาหาร และส่วนผสมของอาหาร และจะไม่เรียนรู้ค่าจากประเภทและชนิดของอาหารแต่จะเรียนรู้ถึงผลลัพธ์การทำนายเช่น ถ้ามีบริบทจากชุดข้อมูลถูกนำเข้ามาโมเดลสามารถจำแนกได้ตามประเภทและชนิดของอาหารตามตัวเลขที่กำหนดให้

### 4.2.Word Tokenization :

คณะผู้จัดทำต้องการแยกคำออกจากประโยคเพื่อนำไปพิจารณาในการนับจำนวนของคำที่มีลักษณะที่เหมือนกัน โดยในการทำงานของขั้นตอนนี้จะเป็นการแยกคำที่มีความหมายออก

จากประโยคถูกนำเข้ามา จะเป็นการตัดคำและนำมาเก็บไว้ในตัวแปรเก็บข้อมูลโดยแต่ละคำที่ตัดจะต้องมีความหมายทุกคำ

#### **4.3.Word Count :**

คณะผู้จัดทำต้องการนับคำที่มีความหมายและลักษณะการเขียนที่เหมือนกันและอยู่ในลักษณะหรือรูปร่างเดียวกัน เพื่อหาจำนวนที่มากที่สุดของชุดข้อมูลสำหรับการกำหนดขนาดของข้อมูลในการเรียนรู้โมเดล

#### **4.4.Word Vectoriztion :**

คณะผู้จัดทำต้องการแปลงคำศัพท์ในประโยคเป็นเวกเตอร์ที่มีค่าตัวเลขเพื่อใช้ในการคำนวณและวิเคราะห์ข้อมูล โดยเวกเตอร์ที่ใช้มีค่าตัวเลขแตกต่างกันออกไปตามความหมายของคำศัพท์ ดังนั้นคณะผู้จัดทำจึงสามารถใช้เวกเตอร์เหล่านี้ในการหาความสัมพันธ์ระหว่างคำศัพท์ได้และสามารถจำแนกประเภทของอาหารและชนิดของอาหารได้

#### **4.5.One-hot Encoding :**

คณะผู้จัดทำทำการออกแบบชุดข้อมูลที่เหมาะสมสำหรับการเรียนรู้ตัวโมเดล การเรียนรู้ของโมเดลจะเป็นการเรียนรู้ด้วยเมทริกซ์ตัวเลขเท่านั้น ดังนั้นคณะผู้จัดทำต้องทำการแปลงชุดข้อมูลในรูปแบบของคำให้เป็นเมทริกซ์ตัวเลขสำหรับการเรียนรู้โมเดลในขั้นตอนต่อไป


### **5. Classification Models :**

#### **5.1.CNN :**

Convolutional Neural Network(CNN) คือโมเดลเรียนรู้ที่ใช้อย่างแพร่หลาย เพื่อดึงคุณสมบัติหรือลักษณะเฉพาะจากชุดข้อมูล โดยจะประกอบไปด้วยชั้นหลายชั้นเช่น 1.Conv1D layer 2.MaxPooling1D layer 3.Flatten layer 4.Dense layer โมเดล CNN รับชุดข้อมูลผ่าน Embedding layer ส่งต่อไปให้ Conv1D layer และ Maxpooling1D layer เพื่อดึงคุณสมบัติหรือลักษณะเฉพาะจากชุดข้อมูลและลดความซับซ้อนเมทริกซ์ของชุดข้อมูล ส่งต่อไปให้ Flatten layer เพื่อแปลงเมทริกซ์ 2 มิติให้อยู่ในรูปแบบของเวกเตอร์ ส่งต่อไปให้ Dense layer โดยชั้นนี้จะเป็น Fully Connected Layer จะมีลักษณะเป็น Activation Function และจะประกอบไปด้วย ReLU กับ Sigmoid activation function ใช้สำหรับโมเดล CNN และส่งต่อไปให้ชั้นสุดท้ายคือ Dense layer จะใช้ Sigmoid activation function สำหรับทำนายประเภทของอาหารและชนิดของอาหาร

#### **5.2.LSTM :**

Long Short-Term Memory(LSTM) คือโมเดลที่มีการทำงานแบบทิศทางเดียวและสองทิศทาง โดยการทำงานแบบทิศทางเดียวของ LSTM ลำดับการรับข้อมูลเข้าจะส่งย้อนหลังกลับมาข้างหน้าและจะรักษาริบทของอดีต แต่การทำงานแบบสองทิศทางของ LSTM ลำดับการรับข้อมูลเข้าจะส่งย้อนหลังกลับมาข้างหน้าและจะส่งข้างหน้าไปข้างหน้าผ่าน Hidden layer โดยการส่งข้อมูลจะเป็นการปรับค่าน้ำหนักของการเรียนรู้ชุดข้อมูลให้สามารถทำนายได้มีประสิทธิภาพ โมเดล LSTM แบบสองทิศทางสามารถจดจำบริบทจากอดีตและอนาคตโดยจะมีลักษณะการทำงานดังรูปภาพต่อไปนี้



กำหนดให้

$x_t$  คือบริบทที่เป็นอินพุตเวกเตอร์

$h_{t-1}$  คือเอาต์พุตบริบทก่อนหน้า

$c_{t-1}$  คือเซลล์ก่อนหน้าหน่วยความจำ

$h_t$  คือเอาต์พุตบริบทปัจจุบัน

$c_t$  คือเซลล์ปัจจุบันหน่วยความจำ

### 5.3.CNN-LSTM Hybrid Architecture :

แอปพลิเคชัน NLP มีการประยุกต์การใช้งานแบบ Hybrid เพื่อประสิทธิภาพของโมเดลที่ดีขึ้น ในชุดข้อมูลขนาดใหญ่โมเดล CNN สามารถดึงคุณสมบัติหรือลักษณะเฉพาะจากชุดข้อมูลที่อยู่ในรูปแบบของเวกเตอร์จาก Embedding layer ที่ส่งต่อมาจากชุดข้อมูลและรวมคุณสมบัติหรือลักษณะเฉพาะเข้าด้วยกันโมเดล Bi-LSTM ดึงคุณสมบัติหรือลักษณะทั้งหมดจากลักษณะเฉพาะของชุดข้อมูลและทำการจดจำคุณสมบัติหรือลักษณะทั้งหมด ดังนั้นคณะผู้จัดทำได้รวมโมเดล CNN และ Bi-LSTM เข้าด้วยกันเพื่อสร้างโมเดลที่มีประสิทธิภาพมากที่สุด

### Data

คณะผู้จัดทำได้ออกแบบและเก็บชุดข้อมูลสำหรับการเรียนรู้ด้วยตัวเอง เนื่องจากวัตถุประสงค์ของเอกสารการวิจัยของคณะผู้จัดทำต้องการออกแบบโมเดลที่มีประสิทธิภาพเมื่อรับข้อมูลเป็นความต้องการของผู้ใช้งาน โดยผู้ใช้งานจะให้ข้อมูลเป็นประโยคคำถามหรือประโยคที่ไม่บ่งบอกเอกลักษณ์และลักษณะของอาหารที่ผู้ใช้งานต้องการโดยจะไม่บอกชัดเจน โมเดลจะต้องทำนายอาหารที่ผู้ใช้งานต้องการ ดังนั้นชุดข้อมูลนี้เป็นชุดข้อมูลอธิบายถึงรสชาติ คุณลักษณะ ขั้นตอนการทำ รูปร่าง วัฒนธรรมหรือประวัติศาสตร์ สารอาหาร และส่วนผสมของอาหารโดยประกอบ

ด้วย 576 ประโยค 13088 คำและมี 3 หมวดหมู่ตามประเภทของอาหารคือ 1.พิชซ่า 2.สปาเก็ตตี้ 3. ก๋วยเตี๋ยว แต่ละประเภทของอาหารแบ่งออกเป็นอาหารทั้ง 4 ชนิดคือ 1.พิชซ่าจะประกอบไปด้วย 1.1.ค็อกเทลกุ้ง 1.2.มีทเดอลูกซ์ 1.3.เห็ดและมะเขือเทศ 1.4.ดิปเปอร์ คลาสสิก 2.ก๋วยเตี๋ยวจะประกอบไปด้วย 2.1.ก๋วยเตี๋ยวน้ำตก 2.2.ก๋วยเตี๋ยวดมย้า-น้ำใส 2.3.บะหมี่แห้งน้ำ-หมูแดง-หมูกรอบ 2.4.เกาเหลา 3.สปาเก็ตตี้จะประกอบไปด้วย 3.1.สปาเก็ตตี้มีทบอล 3.2.สปาเก็ตตี้คาโบนาร่า 3.3.สปาเก็ตตี้ผัก 3.4.สปาเก็ตตี้ทะเล โดยข้อมูลแต่ละประเภทจะมีจำนวนข้อมูลดังนี้

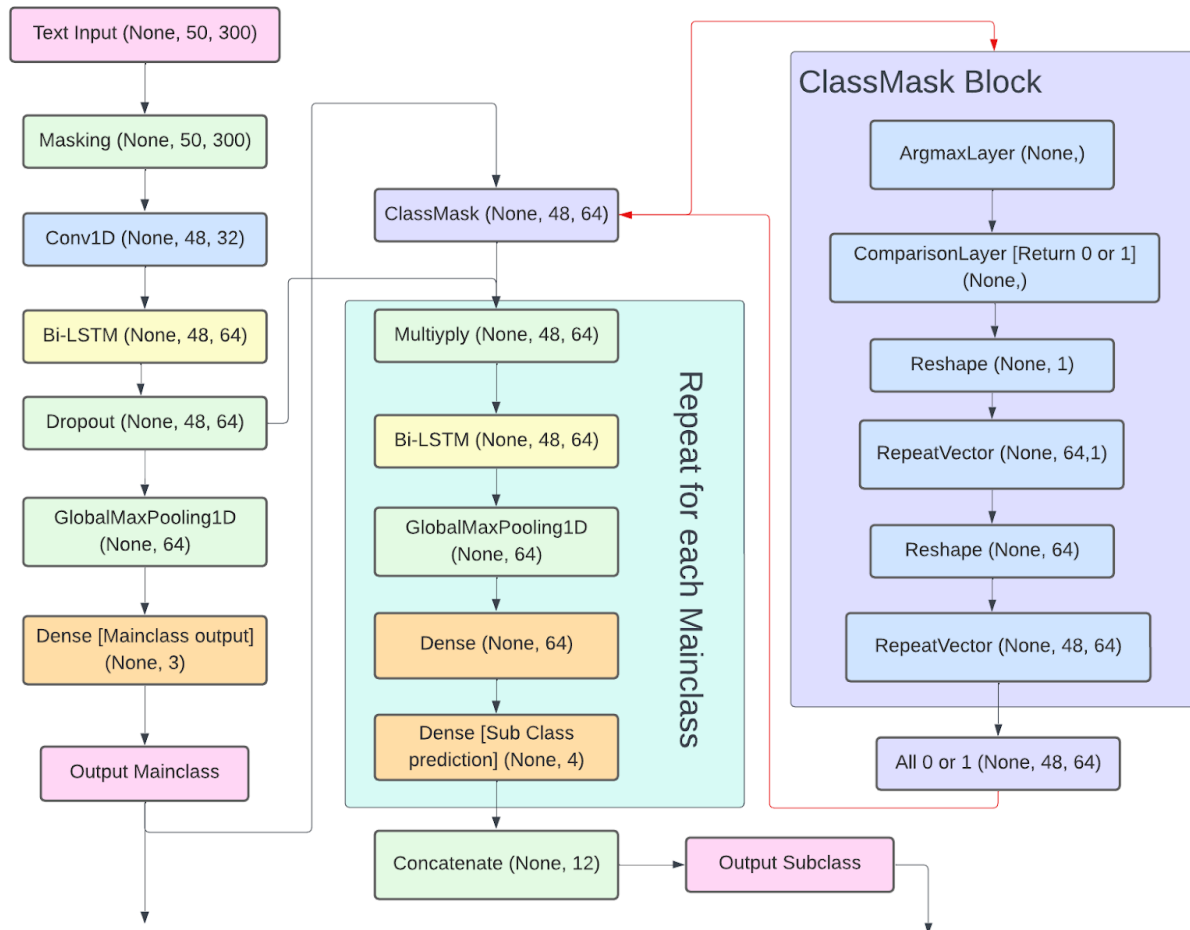
ประเภทอาหาร	ชนิดอาหาร	จำนวนข้อมูล(ประโยค,คำ)
พิชซ่า	พิชซ่าค็อกเทลกุ้ง	(48, 1042)
	พิชซ่ามีทเดอลูกซ์	(48, 1031)
	พิชซ่าเห็ดและมะเขือเทศ	(48, 1030)
	พิชซ่าดิปเปอร์ คลาสสิก	(48, 1101)
ก๋วยเตี๋ยว	ก๋วยเตี๋ยวน้ำตก	(48, 1101)
	ก๋วยเตี๋ยวดมย้า-น้ำใส	(48, 1181)
	บะหมี่แห้งน้ำ-หมูแดง-หมูกรอบ	(48, 1126)
	เกาเหลา	(48, 1043)
สปาเก็ตตี้	สปาเก็ตตี้มีทบอล	(48, 1136)
	สปาเก็ตตี้คาโบนาร่า	(48, 1145)
	สปาเก็ตตี้ผัก	(48, 1017)
	สปาเก็ตตี้ทะเล	(48, 1135)

## Model architecture

คณะผู้จัดทำมีเป้าหมายเพื่อหาโมเดลที่มีประสิทธิภาพสูงสุดสำหรับให้คำแนะนำอาหารที่ผู้ใช้งานรับประทาน โดยรับข้อมูลจากผู้ใช้งานผ่านทางแชทบอท โมเดลจะอ้างอิงจากเอกสารการวิจัยที่เกี่ยวข้องทั้ง 3 ฉบับ เนื่องจากการรับข้อมูลจากผู้ใช้งานส่วนใหญ่จะได้รับข้อมูลที่ไม่บอกลักษณะหรือ

รูปร่าง วัตถุดิบของอาหารอย่างชัดเจนแต่จะเป็นข้อมูลที่บรรยายถึงอาหารแต่ละประเภทและชนิด ดังนั้นคณะผู้จัดทำได้ออกแบบโมเดลสำหรับให้คำแนะนำอาหารกับผู้ใช้งานทั้ง 2 โมเดลดังนี้

### 1.Hierarchical Hybrid (CNN-LSTM) model โดยจะมีลักษณะ



โมเดลนี้จะประยุกต์การใช้งานแบบ Hybrid (CNN-LSTM) เป็นการประยุกต์ร่วมกันกันระหว่างโมเดล Convolution Neural Networks(CNN) ที่มีประสิทธิภาพที่ดีกับข้อมูลที่น้อยกับโมเดล Long Short-Term Memory(LSTM) ที่มีประสิทธิภาพที่ดีในการเรียนรู้และจดจำค่า และโมเดลนี้ประยุกต์ใช้โมเดล Pre-trained ของ Thai2fit ทำการ Embedding ของข้อมูล โดยมีหลักการทำงานดังนี้

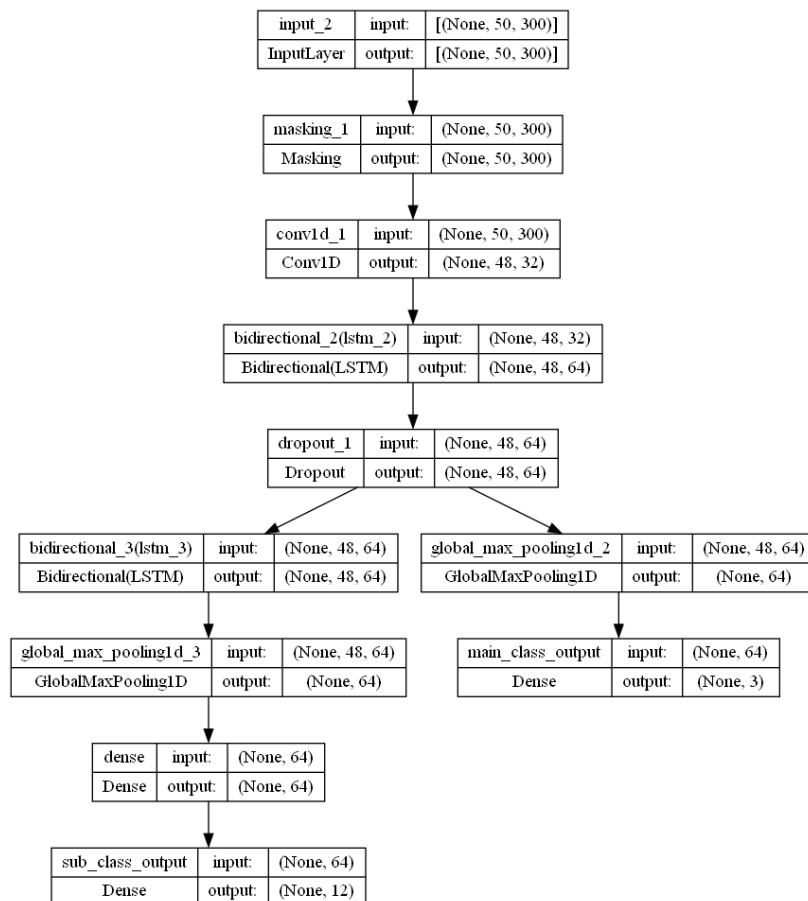
1. ชุดข้อมูลเรียนรู้จะแยกข้อมูลออกเป็นจำนวนข้อมูลของคำบรรยายอาหาร(ประโยคและคำ) และประเภทของอาหาร
2. กำหนดขนาดข้อมูลเมทริกซ์เวกเตอร์ของประเภทอาหารให้เท่ากับขนาดข้อมูลเมทริกซ์เวกเตอร์ของคำบรรยายอาหาร
3. นำข้อมูลเมทริกซ์เวกเตอร์ของประเภทอาหารและคำบรรยายอาหารคูณกัน ผลลัพธ์ได้เมทริกซ์เวกเตอร์ของประเภทที่เราสนใจ

#### 4. นำเมทริกซ์เวกเตอร์ของประเภทที่เราสนใจทำนายชนิดของอาหาร

โมเดลนี้จะมีการทำนายประเภทของอาหารและชนิดของอาหารจากข้อมูลจากผู้ใช้งาน โดยจะรับข้อมูลจากผู้ใช้งานครั้งแรกเข้ามาทำนายประเภทของอาหารและรับข้อมูลอีกครั้งทำนายชนิดของอาหาร และทางคณะผู้จัดทำออกแบบการปรับแต่งพารามิเตอร์เพื่อให้โมเดลที่มีประสิทธิภาพสูงสุดดังรูป

```
Embedding = [300] # pretrained from That2fit
Conv1d = [filters=32, kernel_size=3]
GlobalMaxPooling = [2]
Bi-LSTM Units = [32]
Dropout = [0.2]
Dense = [64,4,3]
Learning rate = [0.001]
Loss = [Categorical crossentropy]
Batch size = [4]
Optimizer = [Adam]
```

#### 2.Base Line Hybrid (CNN-LSTM) model โดยจะมีลักษณะ





โมเดลนี้จะประยุกต์การใช้งานแบบ Hybrid (CNN-LSTM) เป็นการประยุกต์ร่วมกันกันระหว่างโมเดล Convolution Neural Networks(CNN) ที่มีประสิทธิภาพที่ดีกับข้อมูลที่น้อยกับโมเดล Long Short-Term Memory(LSTM) ที่มีประสิทธิภาพที่ดีในการเรียนรู้และจดจำค่า และโมเดลนี้ประยุกต์ใช้โมเดล Pre-trained ของ Thai2fit ทำการ Embedding ของข้อมูล โดยหลักการทำงานคือจะรับข้อมูลจากผู้ใช้งานโดยข้อมูลจะต้องบ่งบอกถึงลักษณะรูปร่างของอาหารหรือสารอาหารหรือข้อมูลที่มีความเกี่ยวข้องกับประเภทของอาหาร โมเดลจะทำนายประเภทของอาหารตามข้อมูลที่ใช้งานระบุ และการทำงานของโมเดลดังนี้

**2.1.Main Class Hybrid (CNN-LSTM) Branch** เป็นโมเดลส่วนที่จะทำนายประเภทของอาหารเท่านั้นและการทำงานของโมเดลดังนี้

1. จะรับชุดข้อมูลจากผู้ใช้งานเข้าไปในโมเดลและทำการเรียนรู้ด้วยโมเดล CNN และ LSTM
2. ข้อมูลที่เรียนรู้เสร็จ จะทำการลดทอนข้อมูลออกไปบางส่วนเพื่อลดการที่โมเดลจะจดจำคำตอบจากการเรียนรู้มาตอบมากเกินไปหรือที่เรียกว่า overfitting
3. ข้อมูลที่ทำการลดทอนเสร็จสิ้น จะแยกการทำงานออกจากกันโดยถ้าโมเดลต้องการที่จะทำนายประเภทของอาหารอย่างเดียวนั้นโมเดลจะแยกไปทำงานในส่วนของทางขวาโดยจะทำนายประเภทของอาหารใน dense main class output layer ทั้งหมด 3 หมวดหมู่ประกอบไปด้วย 1.พืชผัก 2.ก๋วยเตี๋ยว 3.สปาเก็ตตี้

**2.2.Sub Class Hybrid (CNN-LSTM) Branch** เป็นโมเดลส่วนที่จะทำนายชนิดของอาหารเท่านั้น และการทำงานของโมเดลดังนี้

1. จะรับชุดข้อมูลจากผู้ใช้งานเข้าไปในโมเดลและทำการเรียนรู้ด้วยโมเดล CNN และ LSTM
2. ข้อมูลที่เรียนรู้เสร็จ จะทำการลดทอนข้อมูลออกไปบางส่วนเพื่อลดการที่โมเดลจะจดจำคำตอบจากการเรียนรู้มาตอบมากเกินไปหรือที่เรียกว่า overfitting
3. ข้อมูลที่ทำการลดทอนเสร็จสิ้น จะแยกการทำงานออกจากกันโดยถ้าโมเดลต้องการที่จะทำนายชนิดของอาหารอย่างเดียวนั้นโมเดลจะแยกไปทำงานในส่วนของทางซ้ายโดยจะทำนายชนิดของอาหารที่อยู่ในประเภทของอาหารใน dense sub class output layer ทั้งหมด 12 หมวดหมู่ประกอบไปด้วย 1.พืชผักคืออกเทลกุ้ง 2.พืชผักมีทเดอลูกซ์ 3.พืชผักเห็ดและมะเขือเทศ 4.พืชผักดิปเปอร์ คลาสสิก 5.ก๋วยเตี๋ยวน้ำตก 6.ก๋วยเตี๋ยวมั้ยน้ำ-น้ำใส 7.บะหมี่แห้งน้ำ-หมูแดง-หมูกรอบ 8.เกาเหลา 9.สปาเกตตี้มีทบอล 10.สปาเกตตี้คาโบนาร่า 11.สปาเกตตี้ผัก 12.สปาเกตตี้ทะเล

และทางคณะผู้จัดทำออกแบบการปรับแต่งพารามิเตอร์เพื่อให้โมเดลที่มีประสิทธิภาพสูงสุด

ดังรูป

```

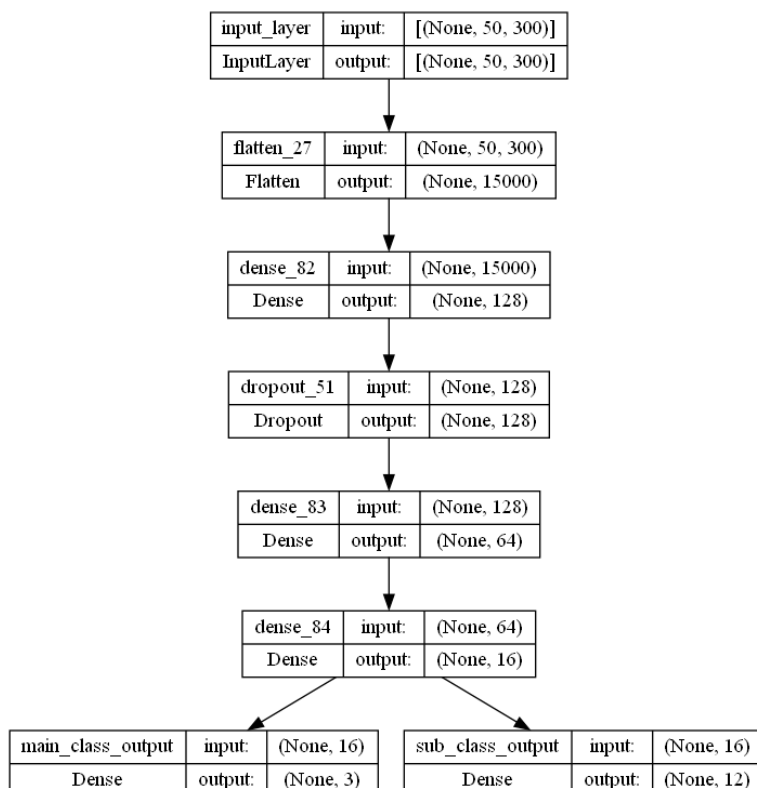
Embedding = [300] # pretrained from That2fit
Conv1d = [filters=32, kernel_size=3]
Bi-LSTM Units = [32]
Dropout = [0.2]
Bi-LSTM Units = [32]
Dense = [32]
Dense output = [12], [3]
Learning rate = [0.001]
Loss = [Categorical crossentropy]
Batch size = [4]
Optimizer = [Adam]

```

## Experimental setting

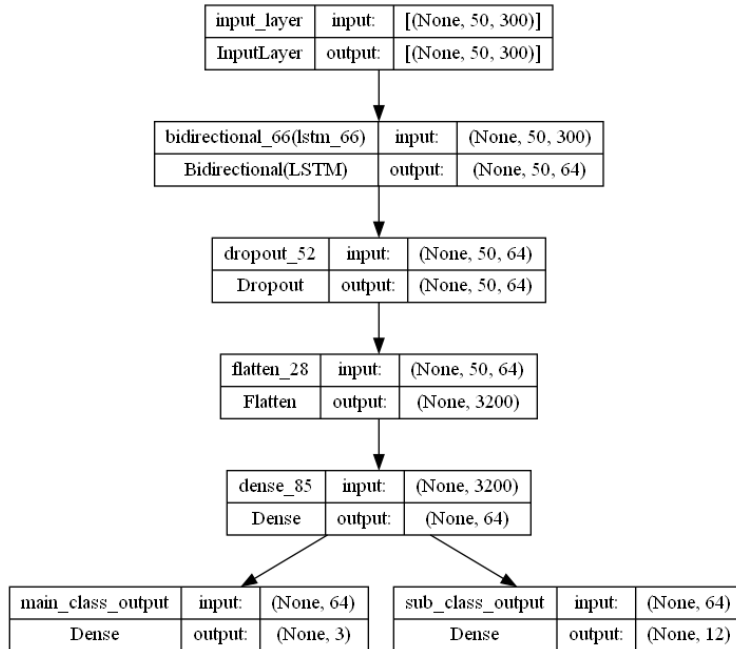
โดยผู้จัดทำได้ทำการออกแบบวิธีการวัดผลและการทดลอง โดยมีเป้าหมายในการเปรียบเทียบผลลัพธ์ของโมเดลที่ได้นำเสนอมาโดยจะมีการเปรียบเทียบกันทั้งหมด 4 โมเดล คือ

### 1. Baseline Neural Network model



เป็นโมเดล Neural Network ที่ประกอบไปด้วย Fully connected layer และ Fatten layer เพียงเท่านั้น โดยในโมเดลจะประกอบไปด้วย Output สองอย่างด้วยกันคือ หมวดหมู่หลักและหมวดหมู่ย่อย

## 2. Baseline Bi-LSTM model



เป็นโมเดลที่ประกอบไปด้วย Bidirectional LSTM (BiLSTM) ที่เหมาะกับการใช้งานในเชิงของ Natural language processing โดยในโมเดลจะประกอบไปด้วย Output สองอย่างด้วยกันคือ หมวดหมู่หลักและหมวดหมู่ย่อย

3. Base Line Hybrid (CNN-LSTM) model
4. Hierarchical Hybrid (CNN-LSTM) model

## Analysis and Results

### Evaluation Metrics

คณะผู้จัดทำได้ทำการวิเคราะห์ผลลัพธ์ของโมเดล โดยผลลัพธ์ที่ทำการวิเคราะห์จะประกอบไปด้วยค่า Precision, Recall และค่า F1-Score ค่าของผลลัพธ์จะอยู่ในรูปแบบของเมทริกซ์และนำค่าผลลัพธ์เมทริกซ์ทำการคำนวณต่อไปตามรูปแบบที่กำหนดดังสมการนี้

$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

กำหนดให้

TP = True Positive(ค่าจริงเป็นจริง และทำนายออกมาเป็นจริง)

FP = False Positive(ค่าจริงเป็นจริง และทำนายออกมาเป็นเท็จ)

TN = True Negative(ค่าจริงเป็นเท็จ และทำนายออกมาเป็นจริง)

FN = False Negative(ค่าจริงเป็นเท็จ และทำนายออกมาเป็นเท็จ)

## Results

คณะผู้จัดทำได้ทดลองนำผลลัพธ์ทั้งจากโมเดลและจาก Confusion matrix มาวิเคราะห์เพื่อ  
ดูประสิทธิภาพของโมเดลและหาปัญหาที่เกิดขึ้น ดังนี้

### 1. Evaluation of Baseline Neural Network model

#### a. หมวดหมู่มาก

	precision	recall	f1-score	support
0 (พิชซ่า)	0.49	0.52	0.50	33
1 (ก๋วยเตี๋ยว)	0.48	0.70	0.57	40
2 (สปาเก็ตตี้)	0.52	0.28	0.36	43
accuracy			0.49	116
macro avg	0.50	0.50	0.48	116
weighted avg	0.50	0.49	0.47	116

จากตาราง Confusion matrix สังเกตได้ว่าโมเดลไม่สามารถทำนายหมวดหมู่มาก  
หลักไม่ถูกต้องมากนักโดยเฉพาะ สปาเก็ตตี้ ที่มีคะแนน Recall น้อยกว่าหมวดหมู่  
หลักอื่น ๆ อย่างเห็นได้ชัด

#### b. หมวดหมู่น้อย

	precision	recall	f1-score	support
0	0.00	0.00	0.00	11
1	0.25	0.12	0.17	8
2	0.11	0.25	0.15	8
3	0.00	0.00	0.00	6
4	0.19	0.46	0.27	13
5	0.08	0.08	0.08	12
6	0.14	0.29	0.19	7
7	1.00	0.50	0.67	8
8	0.00	0.00	0.00	8
9	0.07	0.10	0.08	10
10	0.50	0.07	0.12	14
11	0.33	0.09	0.14	11
accuracy			0.16	116
macro avg	0.22	0.16	0.16	116
weighted avg	0.23	0.16	0.15	116

จากตาราง Confusion matrix สังเกตได้ว่าโมเดลไม่สามารถทำนายหมวดหมู่ย่อยได้เลยโดยโดยได้คะแนน accuracy อยู่ที่ 0.16 เท่านั้น และในบางหมวดหมู่ไม่มีการทำนาย (0%)

## 2. Evaluation of Baseline Bi-LSTM model

### a. หมวดหมู่หลัก

	precision	recall	f1-score	support
0 (พิษฆ่า)	0.66	0.82	0.73	33
1 (ก๊วยเตี๋ยว)	0.75	0.75	0.75	40
2 (สปาเกตตี้)	0.69	0.56	0.62	43

accuracy			0.70	116
macro avg	0.70	0.71	0.70	116
weighted avg	0.70	0.70	0.69	116

จากตาราง Confusion matrix สังเกตได้ว่าโมเดลสามารถทำนายหมวดหมู่หลักได้ค่อนข้างดีแต่หมวดหมู่หลักประเภท สป่าเกตดี ยังมีคะแนนน้อยกว่าหลักประเภทอื่นอยู่บ้าง

b. หมวดหมู่น้อย

	precision	recall	f1-score	support
0	0.54	0.64	0.58	11
1	0.29	0.50	0.36	8
2	0.10	0.12	0.11	8
3	0.25	0.17	0.20	6
4	0.43	0.46	0.44	13
5	0.38	0.25	0.30	12
6	0.20	0.29	0.24	7
7	0.44	0.50	0.47	8
8	0.31	0.50	0.38	8
9	0.50	0.20	0.29	10
10	0.44	0.29	0.35	14
11	0.50	0.36	0.42	11
accuracy			0.36	116
macro avg	0.36	0.36	0.35	116
weighted avg	0.39	0.36	0.36	116

จากตาราง Confusion matrix สังเกตได้ว่าโมเดลนี้ไม่สามารถทำนายหมวดหมู่ย่อยได้อย่างแม่นยำ (Accuracy โดยรวมประมาณ 0.36) แต่ไม่พบหมวดหมู่ย่อยที่โมเดลไม่สามารถทำนายได้

### 3. Evaluation of Base Line Hybrid (CNN-LSTM) model

#### a. หมวดหมู่หลัก

	precision	recall	f1-score	support
0 (พิชซ่า)	0.62	0.91	0.74	33
1 (ก๋วยเตี๋ยว)	1.00	0.70	0.82	40
2 (สปาเกตตี้)	0.78	0.72	0.75	43
accuracy			0.77	116
macro avg	0.80	0.78	0.77	116
weighted avg	0.81	0.77	0.77	116

จากตาราง Confusion matrix สังเกตได้ว่าหมวดหมู่หลัก 'ก๋วยเตี๋ยว' มีค่า Recall ที่ต่ำอาจจะเป็นเพราะในชุดข้อมูลหมวดหมู่ก๋วยเตี๋ยวมียาค่อยๆ คล้ายกับอีกสองหมวดหมู่ (พิชซ่าและสปาเกตตี้) และไม่มีคีย์เวิร์ดที่บ่งบอกลักษณะแน่ชัดของคำ เช่น ก๋วยเตี๋ยวกับสปาเกตตี้ที่มีคำว่าเส้นเหมือนกัน หรือรสชาติที่คล้ายกันในบางเมนู ทำให้ในบางครั้งโมเดลไม่สามารถระบุได้ว่าเป็นก๋วยเตี๋ยวจริงๆ แต่เมื่อโมเดลสามารถหา ก๋วยเตี๋ยวเจอ ก็จะทำนายว่าเป็นก๋วยเตี๋ยวได้แม่นยำกว่าอีกสองหมวดหมู่ที่เหลือ โดยสังเกตได้จากค่า Precision ของหมวดหมู่ก๋วยเตี๋ยวที่มากที่สุด ในส่วนถัดไปคณะผู้จัดทำได้ทดลองตั้งประโยคบางประโยคที่โมเดลทำนายผิดมาวิเคราะห์ได้ดังนี้

ประโยค	ผลเฉลย	ทำนาย
อยากกินก๋วยเตี๋ยวที่ใส่น้ำ เพราะเราเป็นคนไม่กินหมูพอจะมีอะไรแนะนำมั้ย	ก๋วยเตี๋ยว	พิชซ่า
อาหารที่มีส่วนผสมคือไข่และชีสหอม ๆ กับครีมซอสที่เข้มข้นน่ากินมาก	สปาเกตตี้	พิชซ่า
อยากได้เมนูที่มีแป้ง และมีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ	สปาเกตตี้	พิชซ่า
อยากได้ความเค็มกับความเหนียวของเนื้อกุนเชียงกับเส้น และซอสที่ทำจากมะเขือเทศ	สปาเกตตี้	ก๋วยเตี๋ยว



พิซซ่าที่เราสามารถลองซอสพิซซ่าได้มากถึง 4 ซอสสูตรเด็ดภายในพิซซ่าตัวนี้ได้เลย	พิซซ่า	ถ้วยเดียว
อยากกินอาหารทะเล ประเภทแป้งที่เป็นเส้น มีความเหนียวหนึบ อาจจะมีซอสซีฟู้ดเป็นเครื่องเคียงด้วย	สปาเกตตี	ถ้วยเดียว
พิซซ่าที่มีกุ้ง เห็ด สับปะรด มันชื่อว่าพิซซ่าอะไร	พิซซ่า	สปาเกตตี
สามารถหาซื้อได้จากร้านสะดวกซื้อร้านอาหารทั่วไป มีแป้งและไขมันเยอะ และโปรตีนเล็กน้อย	สปาเกตตี	พิซซ่า
อยากกินเบคอน บาร์บีคิว ชิกเก้น และเป๊ปเปอร์โรนี ขอเป็นอาหารแป้งๆ ร้อนๆ และกินง่ายๆ ใช้อมือกินได้ เป็นอาหารต่างประเทศด้วย	พิซซ่า	สปาเกตตี
อยากกินสปาเกตตีผัด	สปาเกตตี	ถ้วยเดียว
อยากอาหารที่เป็นเส้นรสชาติเปรี้ยวๆ เผ็ดๆ	ถ้วยเดียว	สปาเกตตี
ฉันเป็นคนที่ไม่ค่อยกินเนื้อสัตว์เท่าไรมีสปาเกตตีอะไรที่แนะนำฉันมั้ย	สปาเกตตี	พิซซ่า

จากตารางคณะผู้จัดทำสามารถวิเคราะห์และสรุปผลได้ดังนี้

- ประโยคส่วนใหญ่ที่ทำนายผิดจะประกอบด้วยชื่อของหมวดหมู่หลักอยู่ในประโยค (เช่น พืชชา, ถ้วยเดียว, และสปาเกตตี)
- บางส่วนของประโยคที่ไม่ระบุรายละเอียดที่สำคัญและมีความกำกวม เช่น 'อยากได้เมนูที่มีแป้ง และก็มีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ' หรือ 'สามารถหาซื้อได้จากร้านสะดวกซื้อร้านอาหารทั่วไป มีแป้งและไขมันเยอะ และโปรตีนเล็กน้อย' ที่ไม่ระบุรายละเอียดว่าเป็นเส้นหรือไม่ มีแค่ระบุเป็นแป้ง (ทั้งสามหมวดหมู่หลักมีความเป็นแป้งคล้ายคลึงกัน) สร้างความสัมพันธ์ระหว่างสปาเกตตีและพิซซ่าในโมเดล

#### b. หมวดหมู่อ้อย

	precision	recall	f1-score	support
0	0.62	0.73	0.67	11
1	0.60	0.75	0.67	8
2	0.20	0.50	0.29	8
3	0.50	0.33	0.40	6

4	0.50	0.23	0.32	13
5	0.36	0.33	0.35	12
6	0.29	0.29	0.29	7
7	1.00	0.25	0.40	8
8	0.43	0.38	0.40	8
9	0.30	0.30	0.30	10
10	0.24	0.29	0.26	14
11	0.56	0.45	0.50	11
accuracy			0.40	116
macro avg	0.47	0.40	0.40	116
weighted avg	0.46	0.40	0.40	116

จากตาราง Confusion matrix โมเดลนี้ไม่สามารถทำนายหมวดหมู่ย่อยได้อย่างแม่นยำ (Accuracy โดยรวมประมาณ 0.40) เป็นผลมาจากในแต่ละเมนูย่อยมีลักษณะคำและข้อความคล้ายคลึงกัน เช่น มีวัตถุดิบ, รูปร่าง, และรสชาติเหมือนกัน ยกตัวอย่างเช่น พืชชำเห็ดและมะเขือเทศ มีค่าที่เป็นคีย์เวิร์ดที่พบได้ภายในชุดข้อมูลเมนูอื่นๆ คือ เห็ด (พบได้ภายในชุดข้อมูลสปาเกตตี้) มะเขือเทศ (เป็นส่วนประกอบหลักของพืชชำและบางเมนูในสปาเกตตี้) ทำให้โมเดลสามารถทำนายเมนูนี้ได้ไม่แม่นยำ

ในส่วนถัดไปคณะผู้จัดทำได้ทดลองตั้งประโยคบางประโยคที่โมเดลทำนายผิดมาวิเคราะห์ได้ดังนี้

ประโยค	ผลเฉลย	ทำนาย
อาหารอิตาลี มีเส้นสปาเกตตี้ มีกุ้งขาวกับกับซอสครีมที่ผสมอย่างลงตัว มีเส้นและกุ้งเป็นหลักไม่	สปาเกตตี้ทะเล	สปาเกตตี้คาโบนาร่า
อยากกินก๋วยเตี๋ยวที่ใส่น้ำ เพราะเราเป็นคนไม่กินหมูพอจะมีอะไรแนะนำมั้ย	ก๋วยเตี๋ยวน้ำตก	ค็อกเทลกุ้ง
อยากได้เมนูที่มีแป้ง และก็มีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ	สปาเกตตี้ผัก	เห็ดและมะเขือเทศ

วันนี้ทำงานค่อนข้างเหนื่อย อยากกินอาหารเบาๆ ไม่หนัก แบบพิซซ่า แต่ยังมีความอยากกินชีสอยู่ ไม่เอาพวกเนื้อ	สปาเกตตีผัก	เห็ดและมะเขือเทศ
อาหารที่อร่อยอยู่แล้วมีความกรอบของกากหมูมีความนุ่มของเนื้อที่ตมมากับเส้นก๋วยเตี๋ยวเหนียวนุ่มกำลังดี ใส่เลือดสัตว์แล้วตมให้สุก	ก๋วยเตี๋ยวน้ำตก	ก๋วยเตี๋ยวดัมยำน้ำใส
พิซซ่าที่มีกุ้ง เห็ด สับปะรด มันชื่อว่าพิซซ่าอะไร	ค็อกเทลกุ้ง	สปาเกตตีทะเล
อาหารที่คนออกกำลังกายอยากกินเสร็จผสมด้วยเนื้อสัตว์ และเส้นสปาเกตตี	สปาเกตตีมีทบอล	สปาเกตตีคาโบนาร่า
ถ้าต้องการอาหารประเภทน้ำที่มีเส้นอยู่ด้วยแล้วให้พลังงานเยอะเพราะมีไขมันกับโปรตีนและคาโบไฮเดรต	บะหมี่หมูแดงหมูกรอบ	สปาเกตตีมีทบอล
ต้องการอะไรที่กินง่ายๆ ไม่ต้องเตรียมของมากเน้นเนื้อไม่เน้นผัก	มีทเดอลูกซ์	เห็ดและมะเขือเทศ
อาหารที่มีรสเผ็ดกินกับหมูที่มีความนุ่มกับน้ำซุซุที่เข้มข้นจัดจ้าน	ก๋วยเตี๋ยวน้ำตก	บะหมี่หมูแดงหมูกรอบ

จากตารางคณะผู้จัดทำสามารถวิเคราะห์และสรุปผลได้ดังนี้


- สาเหตุที่โมเดลทำนายผิดในบางประโยค มีผลมาจากการทำนายหมวดหมู่อหลัก เมื่อมีชื่อหมวดหมู่อหลักประกอบอยู่ในประโยคโมเดลจะทำนายผิด
- โมเดลยังสามารถทำนายหมวดหมู่อย่อยได้ไม่แม่นยำนัก เป็นผลมาจากประโยคหลายๆ ประโยคในชุดข้อมูลมีคำที่คล้ายคลึงกัน เช่น 'ถ้าต้องการอาหารประเภทน้ำที่มีเส้นอยู่ด้วยแล้วให้พลังงานเยอะเพราะมีไขมันกับโปรตีนและคาโบไฮเดรต' ในประโยคนี้อีกคำว่า เส้น ไขมัน โปรตีน คาโบไฮเดรต ซึ่งในชุดข้อมูลของเมนูอื่นๆ ก็มีคำที่คล้ายกับคำเหล่านี้ อีกทั้งประโยคในชุดข้อมูลอาจจะมีคำที่บ่งบอกถึงลักษณะเฉพาะของเมื่อนั้นน้อยไป เช่น 'อยากได้เมนูที่มีแป้ง และก็มีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ' ประโยคนี้ไม่สามารถระบุได้ชัดเจนว่าเป็นเมนูใด ทำให้โมเดลมีโอกาสทำนายผิดพลาดสูง

#### 4. Evaluation of Hierarchical Hybrid (CNN-LSTM) models

##### a. หมวดหมู่อหลัก

โดยโครงสร้างของโมเดลที่ได้นำมาทดสอบจะเป็นการใช้ Layers และ Weights ที่ได้

จากการ Train Model Hierarchical Hybrid (CNN-LSTM) โดยจะมีลักษณะดังนี้



	precision	recall	f1-score	support
0 (พิชซ่า)	0.74	0.79	0.76	33
1 (ก๋วยเตี๋ยว)	0.85	0.85	0.85	40
2 (สปาเกตตี้)	0.71	0.67	0.69	43
accuracy			0.77	116
macro avg	0.77	0.77	0.77	116
weighted avg	0.77	0.77	0.77	116

จากตาราง Confusion matrix สังเกตได้ว่าหมวดหมู่หลัก 'สปาเกตตี้' มีค่า Recall ที่ต่ำ สาเหตุเกิดจากในชุดข้อมูลหมวดหมู่สปาเกตตี้มีค่าที่คล้ายคลึงกับอีกสองหมวดหมู่ (พิชซ่าและก๋วยเตี๋ยว) และไม่มีคีย์เวิร์ดที่บ่งบอกลักษณะแน่ชัดของหมวดหมู่ของอาหาร เช่น พิชซ่ากับสปาเกตตี้ก็มีคำว่าชีส, แป้ง, และอิตาลีเหมือนกัน แต่ในชุดข้อมูลพิชซ่าจะมีลักษณะรูปร่างบอก เช่น วงกลมหรือวงรี ในส่วนของก๋วยเตี๋ยวกับสปาเกตตี้ก็มีคำว่าแป้งหรือเส้นเหมือนกัน แต่ในชุดข้อมูลก๋วยเตี๋ยวจะมีคำเพิ่มเติม

เช่น ไทยหรือจีน เพราะสาเหตุนี้ ‘สปาเกตตี’ จึงอยู่ตรงกลางระหว่างสองหมวดหมู่คือ พืชชาและก๋วยเตี๋ยว เป็นผลให้โมเดลไม่สามารถทำนายเป็นสปาเกตตีได้ อย่างไรก็ตามประสิทธิภาพดีขึ้นเมื่อเทียบกับโมเดล Baseline คือ

- สามารถระบุหมวดหมู่หลัก ‘ก๋วยเตี๋ยว’ แม่นยำได้มากขึ้น (สังเกตจากค่า Recall) แต่อีกสองหมวดหมู่หลักลดลง
- มีความแม่นยำในการทำนาย ‘พืชชา’ มากขึ้น (สังเกตจากค่า Precision)

ในส่วนถัดไปคณะผู้จัดทำได้ทดลองดึงประโยคบางประโยคที่โมเดลทำนายผิดมาวิเคราะห์ได้ดังนี้

ประโยค	ผลเฉลย	ทำนาย
ไปเที่ยวทะเล พอดีหาเมนูเกี่ยวกับซีฟู้ด โดยมีความเป็นอาหารต่างชาติ แต่มีรสชาติเผ็ดแบบไทยๆ พอดีโอเคหรือไม่	สปาเกตตี	ก๋วยเตี๋ยว
วันนี้ทำงานค่อนข้างเหนื่อย อยากกินอาหารเบาๆ ไม่หนักแบบพืชชา แต่ยังมีรสชาติอร่อยๆ ไม่เอาพวกเนื้อ	สปาเกตตี	ก๋วยเตี๋ยว
อยากกินสปาเกตตี ที่ใส่กุ้ง ใส่หมึกช่วยแนะนำหน่อย	สปาเกตตี	พืชชา
อยากกินเส้นผสมกับต้มยำ มีรสชาติเผ็ด เปรี้ยว เค็ม และมีเส้นนุ่มๆ จากก๋วยเตี๋ยว สีสันชุ่มฉ่ำมีสีส้มเข้ม ดูจัดจ้าน	ก๋วยเตี๋ยว	สปาเกตตี
อยากได้เมนูที่มีแป้ง และก็มีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ	สปาเกตตี	พืชชา
อยากกินอาหารเผ็ดๆ ใส่พริกเยอะๆ มีรสชาติหลากหลาย เป็นเมนูขึ้นชื่อของไทย นำมาผสมกับประเทศจีน	ก๋วยเตี๋ยว	สปาเกตตี
มีส่วนผสมเป็นน้ำ น้ำมันมะกอก และเกลือ นำขึ้นตั้งไฟต้มจนน้ำเดือดแล้วใส่เส้นลงไปต้ม หมั่นคนเพื่อไม่ให้เส้นติด ต้มจนเส้นสุก กินคู่กับเนื้อ	สปาเกตตี	ก๋วยเตี๋ยว
พืชชาที่มีสีเขียวเยอะ มีลักษณะเป็นวงกลมสลับกับสีขาวจากผักต่าง ๆ	พืชชา	สปาเกตตี
ฉันอยากกินอะไรหลายๆ อย่างมีเมนูอะไรที่สั่งแล้วกินอะไรหลายอย่างมั้ย	พืชชา	สปาเกตตี
แนะนำที่ใช้การอบ ที่มีการใส่กุ้ง ชีส สับปะรด มะเขือเทศ	พืชชา	สปาเกตตี

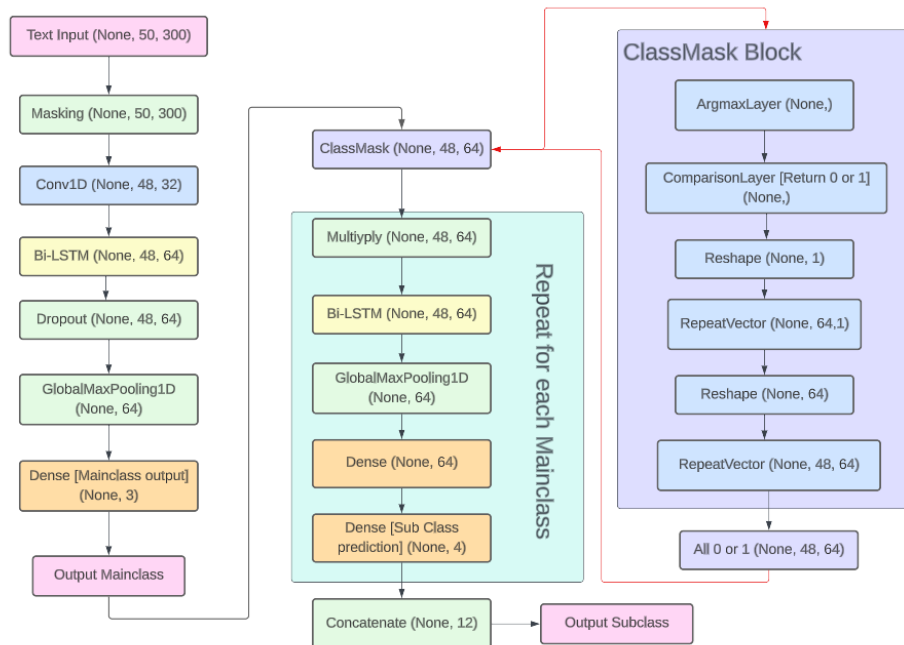
จากตารางคณะผู้จัดทำสามารถวิเคราะห์และสรุปผลได้ดังนี้

- ประโยคโดยส่วนใหญ่ที่โมเดลทำนายผิดจะมีชื่อของหมวดหมู่หลักอยู่ในประโยค (เช่น พืชชา, ก๋วยเตี๋ยว, และสปาเกตตี)

- ประโยคที่มีรายละเอียดน้อยและมีความกำกวมระหว่างสองหมวดหมู่หลัก เช่น 'อยากได้เมนูที่มีแป้ง และมีผักเยอะๆ ที่เคี้ยวง่ายๆ ไม่ต้องออกแรงเยอะ' ที่ไม่ได้ลงรายละเอียดว่าเป็นเส้นหรือไม่ทำให้โมเดลสับสนระหว่างสปาเกตตีกับพืชมะ (อาจจะไปใกล้เคียงกับก๋วยเตี๋ยวด้วยแต่ในชุดข้อมูลคลาสก๋วยเตี๋ยวจะมีพวกคำว่า 'เหนียว' หรือ 'หนึบ' ทำให้โมเดลยังพอแยกออก)
- ในประโยคทั่วไป โมเดลมักจะทำนายระหว่าง 'ก๋วยเตี๋ยว' กับ 'สปาเกตตี' ผิดเป็นเพราะสองหมวดหมู่นี้มีความใกล้เคียงกันทั้งรูปลักษณ์, วัตถุดิบ, และวิธีการประกอบอาหาร

b. หมวดหมู่น้อย

โดยโครงสร้างของโมเดลที่ได้นำมาทดสอบจะเป็นการใช้ Layers และ Weights ที่ได้จากการ Train Model Hierarchical Hybrid (CNN-LSTM) โดยจะมีลักษณะดังนี้



	precision	recall	f1-score	support
0	0.50	0.45	0.48	11
1	0.46	0.75	0.57	8
2	0.25	0.12	0.17	8
3	0.38	0.50	0.43	6
4	0.78	0.54	0.64	13

5	0.31	0.33	0.32	12
6	0.50	0.57	0.53	7
7	0.60	0.75	0.67	8
8	0.20	0.25	0.22	8
9	0.00	0.00	0.00	10
10	0.40	0.43	0.41	14
11	0.46	0.55	0.50	11
accuracy			0.43	116
macro avg	0.40	0.44	0.41	116
weighted avg	0.41	0.43	0.41	116

จากตาราง Confusion matrix สังเกตว่าโมเดลสามารถหาหรือระบุหมวดหมู่ย่อยจริงส่วนใหญ่ได้ไม่ดีสังเกตจากค่า Recall ที่น้อย อาจจะเป็นเพราะเมนูแต่ละเมนูมีความใกล้เคียงกัน เช่น มีวัตถุดิบ, ส่วนประกอบ, หรือลักษณะรูปร่างคล้ายคลึงกัน แต่ในบางเมนูอย่าง ‘สปาเกตตีคาโบนาร่า’ โมเดลไม่สามารถตรวจจับเมนูนี้ได้เลย (ค่า Recall เป็น 0) ซึ่งทางคณะผู้จัดทำยังไม่แน่ใจในปัญหาส่วนนี้ ถัดไปคณะผู้จัดทำได้ทดลองดึงประโยคบางประโยคที่โมเดลทำนายผิดมาวิเคราะห์ได้ดังนี้

ประโยค	ผลเฉลย	ทำนาย
อาหารที่คนออกกำลังกายอยากกินเสร็จผสมด้วยเนื้อสัตว์และเส้นสปาเกตตี	สปาเกตตีมีทบอล	สปาเกตตีผัก
ไปเที่ยวทะเล พอดีหาเมนูที่เกี่ยวกับซีฟู้ด โดยมีความเป็นอาหารต่างชาติ แต่มีรสชาติเผ็ดแบบไทยๆ พอดีไอเดียหรือไม่	สปาเกตตีทะเล	ก๋วยเตี๋ยวน้ำตก
อาหารที่มีซอสสีขาวๆราดอยู่เล็กน้อยหรือมากก็ได้มีรสชาติหวานเค็มมากๆ มีผักอยู่บ้าง มีการโรยชีสและมีแฮม	สปาเกตตีคาโบนาร่า	ดิปเปอร์
อยากกินสปาเกตตีผัก	สปาเกตตีผัก	เห็ดและมะเขือเทศ
พิซซ่าที่มีกุ้ง เห็ด สับปะรด มันชื่อว่าพิซซ่าอะไร	ค็อกเทลกุ้ง	สปาเกตตีทะเล
อาหารสปาเกตตีที่มีการทำ 3 ขั้นตอนคือการที่นำเนื้อสัตว์	สปาเกตตีมี	สปาเกตตีผัก

ไปทอดกับการที่เคียวซอสมะเขือเทศและการต้มเส้นพาสต้า	ทบอล	
อยากกินอาหารทะเล ประเภทแป้งที่เป็นเส้น มีความเหนียวหนึบ อาจจะมีซอสซีฟู้ดเป็นเครื่องเคียงด้วย	สปาเกตตีทะเล	บะหมี่หมูแดงหมูกรอบ
อยากกินอาหารเผ็ดๆ ใส่พริกเยอะๆ มีรสชาติหลากหลาย เป็นเมนูขึ้นชื่อของไทย นามาสสมกับประเทศจีน	ก๋วยเตี๋ยวต้มยำน้ำใส	สปาเกตตีผัก
สามารถหาซื้อได้จากร้านสะดวกซื้อร้านอาหารทั่วไป มีแป้งและไขมันเยอะ และโปรตีนเล็กน้อย	สปาเกตตีคาโบนาร่า	มีทเดอลูกซ์
อาหารที่นิยมสำหรับคนไทยเนื่องจากมีความเผ็ดและเปรี้ยวที่มีเอกลักษณ์ ใส่เครื่องปรุง น้ำตาลทราย น้ำมะนาว น้ำปลา พริกแห้งคั่วบ่น และน้ำพริกเผา	ก๋วยเตี๋ยวต้มยำน้ำใส	บะหมี่หมูแดงหมูกรอบ

จากตารางคณะผู้จัดทำสามารถวิเคราะห์และสรุปผลได้ดังนี้

- โมเดลมีการทำนายหมวดหมู่ย่อยผิดกันเองภายในหมวดหมู่หลัก เป็นเพราะในแต่ละหมวดหมู่ย่อยมีประโยคหรือชุดข้อมูลที่มีคำหรือคีย์เวิร์ดที่คล้ายๆ กัน ยกตัวอย่างประโยค 'อาหารที่คนออกกำลังกายอยากกินเสร็จผสมด้วยเนื้อสัตว์และเส้นสปาเกตตี' ที่ทำนาย 'สปาเกตตีมีทบอล' ออกเป็น 'สปาเกตตีผัก' ซึ่งเกิดจากในชุดข้อมูลของทั้งสองเมนูนี้มีคำว่า 'ผัก' อยู่ เป็นเหตุทำให้โมเดลสับสนระหว่างสองเมนูนี้ได้
- มีบางประโยคที่เมื่อมีชื่อของหมวดหมู่หลักแล้วโมเดลจะทำนายผิด ยกตัวอย่างประโยค 'อยากกินสปาเกตตีผัก' ที่ทำนาย 'สปาเกตตีผัก' ออกเป็น 'พิซซ่าเห็ดและมะเขือเทศ'
- โมเดลยังมีการทำนายหมวดหมู่หลักผิดอยู่บางประโยค แต่โมเดลสามารถทำนายหมวดหมู่ย่อยได้ถูกมากขึ้น ยกตัวอย่าง 'พิซซ่าที่มีกุ้ง เห็ด สับปะรด มันชื่อว่าพิซซ่าอะไร' โมเดลไม่สามารถทำนายเป็นพิซซ่าได้ แต่สามารถทำนายเป็นเมนูที่เกี่ยวข้องกับทะเล (กุ้ง) คือสปาเกตตีทะเล ซึ่งเป็นหมวดหมู่ย่อยทะเลเหมือนกัน

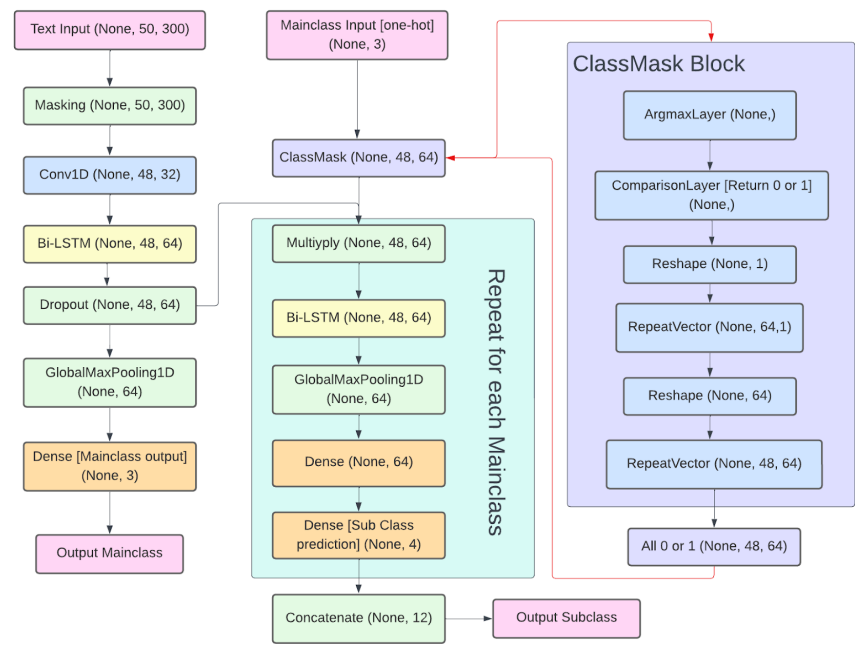
## 5. Evaluation of Hierarchical Hybrid (CNN-LSTM) models (Interaction)

### a. หมวดหมู่ย่อย

โดยโครงสร้างของโมเดลที่ได้นำมาทดสอบจะเป็นการใช้ Layers และ Weights ที่ได้



จากการ Train Model Hierarchical Hybrid (CNN-LSTM) โดยจะมีลักษณะดังนี้



	precision	recall	f1-score	support
0	0.73	0.73	0.73	11
1	0.50	0.75	0.60	8
2	0.67	0.25	0.36	8
3	0.43	0.50	0.46	6
4	0.78	0.54	0.64	13
5	0.57	0.67	0.62	12
6	0.57	0.57	0.57	7
7	0.70	0.88	0.78	8
8	0.29	0.50	0.36	8
9	1.00	0.10	0.28	10
10	0.56	0.64	0.60	14
11	0.83	0.91	0.87	11

accuracy			0.59	116
macro avg	0.64	0.59	0.56	116
weighted avg	0.65	0.59	0.58	116

จากตาราง Confusion matrix สังเกตได้ว่าหมวดหมู่ย่อยที่อยู่ภายใน 'พิชซ่า' โมเดลสามารถหาหรือระบุได้ดี (จากค่า Recall ของ ค็อกเทลกุ้ง, และมีทเดอลูกซ์) ยกเว้นเห็ดและมะเขือเทศ, และดิบเปอร์ ซึ่งอาจจะเป็นผลมาจากพิชซ่าเห็ดและมะเขือเทศเป็นเมนูที่มีวัตถุดิบใกล้เคียงกับเมนูอื่นๆ เช่น ผัก เห็ด ส่วนดิบเปอร์เป็นเมนูที่รวมวัตถุดิบหลายอย่างจากเมนูอื่นๆ เข้าด้วยกัน ทำให้โมเดลอาจจะระบุยากว่าที่ทำนายอยู่เป็นพิชซ่าเห็ดและมะเขือเทศหรือดิบเปอร์จริงๆ ในส่วนของหมวดหมู่ย่อยที่อยู่ภายใน 'ก๋วยเตี๋ยว' หลายๆ เมนูมีค่า Recall ค่อนข้างต่ำยกเว้นเกาเหला ซึ่งสิ่งที่ทำให้โมเดลระบุเกาเหलाได้ดีคือน่าจะเป็นเพราะชุดข้อมูลประโยคส่วนมากมีคำว่า 'ข้าว' อยู่ ทำให้เกาเหลานั้นแตกต่างกับเมนูอื่นๆ ภายในหมวดหมู่ 'ก๋วยเตี๋ยว' ในส่วนสุดท้ายหมวดหมู่ย่อย 'สปาเกตตี' มีลักษณะคล้ายก๋วยเตี๋ยว คือมีเมนูที่มีค่า Recall สูงเมนูเดียวคือสปาเกตตีทะเล คิดว่าเป็นเพราะสปาเกตตีทะเลมีค่าที่แตกต่างจากเมนูอื่นๆ เช่น กุ้ง ปลา ซีฟู้ด ซึ่งไม่มีคำเหล่านี้ในชุดข้อมูลของเมนูอื่นๆ นอกจากนั้นในชุดข้อมูลอื่นๆ เช่น สปาเกตตีคาโบนาร่า, สปาเกตตีมีทบอล, และสปาเกตตีผัก ยังมีคำคล้ายๆ กัน เช่น โปรตีน เนื้อ ผัก ที่กล่าวมาทำให้โมเดลสามารถหาและระบุสปาเกตตีทะเลได้ดีที่สุดภายในหมวดหมู่ย่อย 'สปาเกตตี' ในส่วนถัดไปคณะผู้จัดทำได้ทดลองตั้งประโยคบางประโยคที่โมเดลทำนายผิดมาวิเคราะห์ได้ดังนี้

ประโยค	ผลเฉลย	ทำนาย
อาหารที่คนอกกำลังกายอยากกินเสร็จผสมด้วยเนื้อสัตว์และเส้นสปาเกตตี	สปาเกตตีมีทบอล	สปาเกตตีผัก
วันนี้ทำงานค่อนข้างเหนื่อย อยากกินอาหารเบาๆ ไม่หนักแบบพิชซ่า แต่ยังมีควมอยากกินชีสอยู่ ไม่เอาพวกเนื้อ	สปาเกตตีผัก	สปาเกตตีมีทบอล
อาหารที่มีความกรอบขายเป็นขาม ๆ เหมาะกับการกินคนเดียวสามารถหาร้านได้ทั่วไป	ก๋วยเตี๋ยวน้ำตก	เกาเหला
อยากกินเห็ด มะเขือเทศ หอมใหญ่ พริกหวาน กินคู่กับชีสหรือซอสมะเขือเทศ บนแป้งร้อนๆ รูปร่างกลมๆ ที่ผ่านการอบมาใหม่ๆ	เห็ดและมะเขือเทศ	มีทเดอลูกซ์
ใช้เวลาหน่อย ใส่เกี๊ยวน้ำได้ เส้นมันๆ รสชาติค่อนข้างจืดไม่เผ็ด มีผักคะน้ารองด้านล่าง สามารถเพิ่มลูกชิ้นได้ บางร้านมีน้ำซอสซีอิ๊วให้ราด	บะหมี่หมูแดงหมูกรอบ	ก๋วยเตี๋ยวดัมยำน้ำใส

ต้องการอะไรที่กินง่ายๆ ไม่ต้องเตรียมของมากเน้นเนื้อไม่เน้นผัก	มีทเดอลูกซ์	ดิปเปอร์
เป็นอาหารที่มีความเป็นไทยเน้นรสชาติที่เค็มและกินคู่กับข้าว	เกาเหลา	บะหมี่หมูแดงหมูกรอบ
อยากกินพิซซ่าหน้าชีฟู้ด มีพริกมะเขือเทศ เห็ด หรือสับปะรด ชีสเยิ้มๆ หวานมันกำลังดี	ค็อกเทลกึ่ง	มีทเดอลูกซ์
พิซซ่าสำหรับคนที่อยากได้วิตามินเพิ่มเติมและไม่ชอบกินเนื้อ ส่วนประกอบหลักคือแป้ง	เห็ดและมะเขือเทศ	มีทเดอลูกซ์
ส่วนใหญ่เป็นสีโทนเหลือง ทั้งจากซอส ชีส ไข่ ตัดกับสีน้ำตาลเข้มของเบคอนที่กรุบกรอบกำลังดี	สปาเกตตีคาโบนาร่า	สปาเกตตีผัก

จากตารางคณะผู้จัดทำสามารถวิเคราะห์และสรุปผลได้ดังนี้

- โมเดลสามารถทำนายประโยคที่มีชื่อของหมวดหมู่หลักได้ใกล้เคียงกับผลเฉลยของหมวดหมู่หลักได้แล้ว เช่น 'วันนี้ทำงานค่อนข้างเหนื่อย อยากกินอาหารเบาๆ ไม่หนักแบบพิซซ่า แต่ยังมีคามอยากกินชีสอยู่ ไม่เอาพวกเนื้อ' สามารถทำนายเป็นสปาเกตตีมีทบอล แต่ยังไม่ค่อยแม่นยำในการทำนายหมวดหมู่ย่อย (ผลเฉลยประโยคข้างต้นคือ สปาเกตตีผัก) อีกหนึ่งตัวอย่างคือ 'อาหารที่คนออกกำลังกายอยากกินเสร็จผสมด้วยเนื้อสัตว์และเส้นสปาเกตตี' สามารถทำนายเป็นหมวดหมู่หลัก 'สปาเกตตี' ได้ แต่หมวดหมู่ย่อยโมเดลยังทำนายผิดอยู่
- บางประโยคมีข้อมูลแค่เบื้องต้น ทำให้โมเดลทำนายไม่แม่นยำ เช่น 'อาหารที่มีความกรอบขายเป็นชาม ๆ เหมาะกับการกินคนเดียวสามารถหาร้านได้ทั่วไป' โมเดลทำนายเป็น เกาเหลา แทนที่จะเป็น ก๋วยเตี๋ยวน้ำตก ซึ่งเข้าใจได้เพราะภายในประโยคไม่มีข้อมูลที่บ่งบอกถึงคุณลักษณะเฉพาะของเมนูเป้าหมายเลย

จากข้อมูลทั้งหมดที่คณะผู้จัดทำได้วิเคราะห์สามารถสรุปออกมาได้ดังนี้

1. ข้อผิดพลาดที่เห็นได้ชัดและเป็นที่น่าสนใจในโมเดล  
คณะผู้จัดทำพบสองปัญหาที่เจอในบางโมเดล คือ ในการทำนายหมวดหมู่หลักของโมเดล Baseline และโมเดล Hierarchical Hybrid (CNN-LSTM) พบว่าเมื่อมีชื่อหมวดหมู่หลัก (พิซซ่า, ก๋วยเตี๋ยว, และสปาเกตตี) อยู่ในประโยค จะทำให้โมเดลทำนายผิดพลาด และอีกปัญหาคือ ในการทำนายหมวดหมู่ย่อยของโมเดล Hierarchical Hybrid (CNN-LSTM) ตัวโมเดลไม่สามารถตรวจหาหรือระบุเมนู 'สปาเกตตีคาโบนาร่า' (ค่า Recall และ Precision เป็น 0)
2. ข้อผิดพลาดที่เกิดขึ้นได้บ่อยและพบทั่วไปในโมเดล

คณะผู้จัดทำได้พบปัญหาที่เจอในทุกโมเดล คือโมเดลทำนายหมวดหมู่ย่อยได้ไม่แม่นยำนัก (ค่าความแม่นยำต่ำกว่า 0.6 ทุกโมเดล) โดยสามารถให้เหตุผลได้ว่าลักษณะอาหารที่เป็นหมวดหมู่ย่อยมีความคล้ายกันเป็นอย่างมาก และมีความหลากหลายในรูปแบบของประโยคที่ไม่มากพอ ข้อผิดพลาดอีกอย่างที่สามารถพบได้ทั่วไปและเห็นได้ชัดคือ ประโยคที่มีคำปฏิเสธอยู่ เช่น “ไม่-” จะมีการทายผิด และประโยคที่สั้นมาก ๆ ก็จะมีการทายผิดเยอะเช่นเดียวกัน

### 3. ข้อผิดพลาดที่เกิดขึ้นอยู่ในการคาดการณ์หรือไม่

ปัญหาการทำนายหมวดหมู่ย่อยของโมเดลไม่ได้แม่นยำนัก คณะผู้จัดทำได้คาดการณ์ไว้อยู่แล้ว เนื่องจากในแต่ละเมนูมีหลายอย่างที่คล้ายคลึงกัน ไม่ว่าจะเป็น วัตถุดิบ, ส่วนประกอบ, ลักษณะรูปร่าง, และรสชาติ ส่งผลให้ประโยคหลายๆ ประโยคในชุดข้อมูลยังมีความกำกวมระหว่างเมนูสองเมนูย่อย ประกอบกับจำนวนประโยคในชุดข้อมูลที่คณะผู้จัดทำสร้างขึ้นมานั้นน้อย ทั้งหมดที่กล่าวมาทำให้โมเดลของคณะผู้จัดทำไม่สามารถทำนายหมวดหมู่ย่อยได้แม่นยำ ในส่วนของปัญหาอีกสองปัญหาที่เจอในบางโมเดล คือ 1. เมื่อมีชื่อหมวดหมู่หลัก (พิซซ่า, ก๋วยเตี๋ยว, และสปาเกตตี) อยู่ในประโยค จะทำให้โมเดลทำนายผิดพลาด 2. ตัวโมเดลไม่สามารถตรวจหาหรือระบุเมนู ‘สปาเกตตีคาโบนาร่า’ ปัญหาเหล่านี้ทางคณะผู้จัดทำไม่ได้คาดการณ์ไว้ และคณะผู้จัดทำยังไม่เข้าใจในปัญหานี้ว่ามีที่มาจากอะไรและยังหาทางแก้ไขไม่ได้


### 4. ข้อเสนอแนะในการพัฒนาต่อ

ในส่วนของปัญหาการทำนายหมวดหมู่ย่อยของโมเดลไม่ได้แม่นยำ คณะผู้จัดทำคิดว่าสามารถแก้ไขได้โดยจัดการประโยคในชุดข้อมูลให้สมบูรณ์ขึ้น ให้ประโยคของแต่ละเมนูมีจำนวนคำที่แสดงลักษณะเฉพาะของเมนูมากขึ้น หรือพยายามทำให้ประโยคระหว่างสองเมนูไม่คล้ายกันจนเกินไป

ในการพัฒนาต่ออาจจะเพิ่มเติมในส่วนที่ทำให้โมเดลสามารถแยกส่วนประโยคและเข้าใจว่าประโยคในส่วนนี้เป็นการบ่งบอกถึงข้อมูลส่วนใดของอาหาร เช่น รสชาติ รสสัมผัส เป็นต้น อีกทั้งยังควรจะพัฒนาให้โมเดลเข้าใจถึงประโยคที่เป็นประโยคปฏิเสธให้ได้ชัดมากยิ่งขึ้น


ผลลัพธ์ในการทำนายหมวดหมู่หลัก

Methods	Classes	Accuracy	Precision	Recall	F1
Neural Network	3	0.49	0.50	0.50	0.48
Bi-LSTM	3	0.70	0.70	0.71	0.70
Hybrid (CNN-LSTM)	3	<b>0.77</b>	<b>0.80</b>	<b>0.78</b>	<b>0.77</b>
Hierarchical Hybrid (CNN-LSTM)	3	<b>0.77</b>	0.77	0.77	<b>0.77</b>



### ผลลัพธ์ในการทำนายหมวดหมู่ย่อย

Methods	Classes	Accuracy	Precision	Recall	F1
Neural Network	12	0.16	0.22	0.16	0.16
Bi-LSTM	12	0.36	0.36	0.36	0.35
Hybrid (CNN-LSTM)	12	0.40	<b>0.47</b>	0.40	0.40
Hierarchical Hybrid (CNN-LSTM)	12	<b>0.43</b>	0.40	<b>0.44</b>	<b>0.43</b>
Hierarchical Hybrid (CNN-LSTM) with Main class input	12	<b>0.59</b>	<b>0.64</b>	<b>0.59</b>	<b>0.56</b>



ผลลัพธ์จากการเปรียบเทียบการทำนายหมวดหมู่หลักและหมวดหมู่ย่อยสามารถสรุปได้ดังนี้ ในการทำนายหมวดหมู่หลัก พบว่าโมเดล Hybrid (CNN-LSTM) สามารถทำนายได้ดีที่สุดโดยมีคะแนน Accuracy, Precision, Recall, F1 โดยรวมที่มากที่สุด แต่โมเดล Hierarchical Hybrid (CNN-LSTM) ก็สามารถทำนายได้ด้วยความแม่นยำที่ใกล้เคียงกัน แต่ในส่วนของการทำนายหมวดหมู่ย่อยโมเดล Hierarchical Hybrid (CNN-LSTM) สามารถทำนายได้ดีที่สุดแต่ก็มีคะแนน Accuracy, Precision, Recall, F1 ไม่ต่างกับ Hybrid (CNN-LSTM) มากนัก โดย Hybrid (CNN-LSTM) มี Precision ที่ดีกว่า แต่เมื่อทำการใช้โมเดล Hierarchical Hybrid (CNN-LSTM) ที่มีการให้หมวดหมู่หลักเป็น Input ด้วยแล้วพบว่าโมเดลมีผลลัพธ์ที่ดีขึ้นอย่างเห็นได้ชัด

## Conclusion

โมเดล Hierarchical Hybrid (CNN-LSTM) เป็นโมเดลที่สามารถทำนายหมวดหมู่หลักและหมวดหมู่ย่อยของประเภทอาหารที่เราต้องการได้โดยเมื่อโมเดลทำการทำนายหมวดหมู่หลักแล้วจะทำการทำนายต่อโดยแยก Branch ไปยัง Layers ที่มีการเรียนรู้กับหมวดหมู่หลักนั้น ๆ โดยเฉพาะโดยข้อมูลข้อความที่จะถูกนำมาให้โมเดลทำนายจะผ่านการ Preprocess และแปลงเป็นเวกเตอร์ด้วยโมเดล Thai2fit ของ PyThaiNLP จากนั้นจะทำการนำไปเข้าโมเดลให้ทำนายต่อไป จากการทำการ

ทดลองเปรียบเทียบผลลัพธ์ในการทำนายของโมเดล Hierarchical Hybrid (CNN-LSTM) เมื่อเทียบกับโมเดลอื่น ๆ จะเห็นได้ว่าโมเดลสามารถพัฒนาผลลัพธ์ในการทำนายหมวดหมู่ย่อยได้ดียิ่งขึ้นแต่ผลลัพธ์ก็ถือว่าไม่ได้มีการพัฒนามากอย่างเห็นได้ชัด โดยปัญหานี้ก็เป็นผลกระทบมาจากการที่ในการทำนายหมวดหมู่หลักโมเดลยังไม่สามารถทำนายได้ดีมากนัก และเมื่อโมเดลมีการทำนายหมวดหมู่หลักที่ผิดก็ส่งผลให้เกิดการทำนายหมวดหมู่ย่อยผิดเช่นเดียวกัน อีกทั้งยังมีปัญหาในเรื่องของ Data set ที่ใช้ให้โมเดลได้ทำการเรียนรู้นั้นมีค่อนข้างน้อย อีกทั้งยังขาดความหลากหลายในรูปแบบของประโยคอีกด้วย ดังนั้นแล้วทางคณะผู้จัดทำจึงเห็นว่าในการพัฒนาต่อ สามารถพัฒนาโครงสร้างในส่วนของการทำนายโมเดลหลักให้มีความแม่นยำมากยิ่งขึ้นได้ อีกทั้งยังมีช่องทางการพัฒนาวิธีการสร้าง Dataset ที่ใช้ในการเรียนรู้ของโมเดลเพื่อให้โมเดลสามารถเรียนรู้ได้ดียิ่งขึ้น

### สมาชิก

ก้องภพ ทองดี 63340500003

ภคพล ลีลาคหกิจ 63340500045

สรพัศ วีระกุล 63340500064

อธิเมศร์ เอียวเจริญ 63340500068